



Tecnológico de Monterrey

Instituto Tecnológico y de Estudios Superiores de Monterrey

Escuela de Ingeniería y Ciencias

Maestría en Inteligencia Artificial Aplicada

Dra. Grettel Barceló Alonso

Dr. Luis Eduardo Falcón Morales

Materia Proyecto integrador

Avance 6. Conclusiones clave

Equipo 11

José Gilberto Amaro Aceves - A01794815

Francisco Antonio Enríquez Cabrera - A01795006

Carlos Eduardo García García - A01795206

08-06-2025

Evaluación del modelo

- ¿El rendimiento del modelo es lo suficientemente bueno para su implementación en producción?

El desarrollo de los múltiples modelos para la exportación del tequila ha sido un desafío para este proyecto. Hoy en día se han implementado varias implementaciones de distintos modelos para desarrollar el problema, siendo GradientBoosting y LSTM los modelos con los mejores desempeños, ver imagen 1 e imagen 2.




Imagen 1. Predicción de exportaciones con GradientBoosting




Imagen 2. Predicción de exportaciones U.S.A. con LSTM haciendo uso de la descomposición de valores como variables exógenas.




Imagen 3. Transformaciones de Fourier




Imagen 4. Zoom a la transformación de Fourier




Imagen 5. Segundo Zoom a transformación de Fourier

Para explicar el desempeño de nuestro modelo, tenemos unas graficas de Fourier conforme a nuestros dos modelos de predicción de LSTM, en la imagen 3 tenemos un panorama más completo del desempeño de nuestros modelos y vemos que en general siguen muy bien las frecuencias bajas de los datos y el modelo batalla en predecir las frecuencias altas tal como podemos ver en la imagen 5, en donde podemos ver que el ruido es tan grande que los picos no los predice, sin embargo, vemos que, en menor medida, sigue la tendencia de los datos lo cual nos da una confianza que el modelo está bien entrenado.

Así mismo, en la imagen 4 tenemos un zoom de esta grafica en donde vemos que nuestros modelos y vemos nuevamente que nuestro modelo esta siguiendo bastante cerca los valores reales en su comportamiento de la frecuencia, nosotros consideramos que a pesar de que nuestras predicciones no son exactas, nuestra predicción sigue muy bien las frecuencias bajas y la tendencia general de los valores, por lo cual pensamos que es un modelo viable para esta problemática.

Por otro lado, el costo computacional de la implementación realizada es relativamente alto ya que se optó por usar un acercamiento de “Walking forward” que se explicara más adelante el porqué de esta decisión. Sin embargo, consideramos que este coste no es elevado ya que la frecuencia de actualización de los datos es de un solo registro de manera mensual y no requiere de una ejecución constante.

- ¿Existe margen para mejorar aún más el rendimiento?

Si, se considera que de momento se cuenta con un estimador decente que tiene espacio para mejorar, a continuación, planteamos las áreas identificadas para mejora.

- A. Identificación e inclusión de las variables exógenas.** El modelo solo utiliza los valores actuales del dataset; introducir algunos indicadores macroeconómicos como el tipo de cambio o bien identificar festividades que impacten en las exportaciones del top 10 de los países.
- B. Implementar una Validación Cruzada por Bloques Temporales.** Dividir la serie temporal por bloques secuenciales para los conjuntos de entrenamiento y validación permite la evaluación por bloque.

Con ello, evitamos el sobreajuste y nos provee de una medida más realista del error futuro esperado. En el caso de esta implementación se usó la metodología de “Walking forward” la cual nos permite dividir los datos en distintas ventanas de entrenamiento y pruebas, como vemos en la imagen 6, al realizar la descomposición de los valores y agregando una línea vertical en el 80% de los datos, bajo una implementación tradicional de división de conjuntos de datos entrenamiento-pruebas podemos ver como esta división en esta ocasión no es la ideal ya que el conjunto de entrenamiento no llega a describir el comportamiento del conjunto de pruebas.

A pesar de que se hizo esta división, consideramos que seguir explorando el ajuste de estas divisiones de ventanas podría brindar mejores resultados para el modelo.

C. Descomposición de los valores de la señal. De momento se ha intentado deconstruir los valores de la señal (el valor total de exportaciones) haciendo una descomposición a sus componentes de tendencia, temporalidad y ruido/residuos (ver imagen 6), sin embargo, consideramos que este acercamiento es correcto y explorar filtros y transformaciones para aplicar a los valores y poder conseguir nuevos valores para permitir a los modelos aprender más sobre los datos puede ayudar a mejorar el desempeño del modelo.




Imagen 6. Descomposición de estacionalidad, tendencia y ruido.

D. Implementación híbrida de modelos. Una solución relacionada a los puntos anteriores es dividir la predicción de los distintos componentes en modelos mas adecuados a su comportamiento, modelar la tendencia con modelos mas sencillos como ARIMA y usar modelos mas sensibles a los cambios inmediatos para el modelado del ruido.

- ¿Cuáles serían las recomendaciones clave para poder implementar la solución?


El código ha sido estructurado mediante tres partes principales:

- Un webscraper para conseguir los datos de la pagina de los informes del CNIT.
- Una implementación de un DVC pipeline para la preparación y preprocesamiento de los datos.
- Modelado de inteligencia artificial.

Para la implementación de esta solución recomendamos mantener actualizados los datos mediante el uso del Webscrapping una vez al mes ya que esta es la frecuencia con la que estos datos son actualizados en el sitio oficial.

Una vez obtenidos los datos actualizados, correr el pipeline de DVC para obtener los conjuntos de datos divididos ya en sus distintos subconjuntos al igual que la separación del conjunto de entrenamiento y pruebas.

Por último, ejecutar el entrenamiento del modelo con los nuevos datos para poder tener siempre el mejor modelo disponible y evitar el “data drift”.



- ¿Qué tareas / procedimientos son accionables para las partes interesadas (stakeholders)?

Stakeholder	Rol	Tarea/Procedimiento
TI /Ciencia de Datos	Desarrollo e implementación del modelo	Automatización, mantenimiento, monitoreo y mejoramiento del modelo.
Exportación / Logística	Coordinación de envíos	Planeación de los envíos, transporte y distribución con base en los datos pronosticados.
Órganos Reguladores	Revisión de los reportes y del cumplimiento normativo	Llevar a cabo una trazabilidad y transparencia con instrumentos como reportes ejecutivos que consideren las proyecciones y los valores actuales de las exportaciones por tipo de Tequila.
Departamento de Ventas	Generación de ingresos y estrategias comerciales	Planeación anticipada de los periodos altos y bajos de la demanda.
Departamento de Inteligencia de Negocio	Desarrollo de Indicadores Clave de Rendimiento	Desarrollo de metas basadas en el modelo implementado. Monitoreo de los Indicadores propuestos.

Plataformas de servicios en la nube más adecuada para implementar la solución de ML

Metodología de Comparación

Instancia de referencia: se mapea la carga local (~6 vCPU y 32 GB RAM) a configuraciones de nube equivalentes para entrenar sin GPU:

- AWS c6a.2xlarge (8 vCPU, 16 GB) $\approx$ 0.17 USD/h en N. Virginia.
- Azure D4ads v5 (4 vCPU, 16 GB) $\approx$ 0.19 USD/h en East US.
- GCP e2-standard-4 (4 vCPU, 16 GB) $\approx$ 0.15 USD/h en us-central-1.
- IBM Cloud VPC 4 vCPU 16 GB $\approx$ 0.13 USD/h en Dallas.

Para inferencia se proyectan instancias “serverless” o endpoints auto-escalables ofrecidos por cada proveedor. Los precios son de tarifa bajo demanda en regiones americanas (AWS, 2025; Azure, 2025; Google Cloud, 2025; IBM Cloud, 2025).

Comparativa Detallada

Amazon Web Services (AWS)

AWS lidera el mercado gracias a Amazon SageMaker, que ofrece notebooks gestionados, AutoML, pipelines, monitoreo de deriva y endpoints *serverless* de baja latencia (Seitinger, 2024). Su nueva región AWS Mexico (Queretaro) brinda residencias locales de datos y latencias < 20 ms para usuarios nacionales (Business Wire, 2025).

- *Facilidad de uso*: SageMaker Studio integra Jupyter con plantillas pre-construidas, reduciendo configuración inicial (Krantz et al., 2024).
- *Escalabilidad/MLOps*: pipelines nativos, instancias spot y chips Trainium aceleran entrenamientos; escalado automático en endpoints (Seitinger, 2024).
- *Costos*: estudios comparativos muestran hasta 37 % menos en entrenamiento de 10 h GPU frente a Azure y 25 % frente a GCP (CloudExpat, 2023).

- *Desventajas:* facturación compleja y curva de aprendizaje alta para nuevos equipos (Opala, 2023).

Microsoft Azure

Azure Machine Learning sobresale en experiencia visual (Designer) y profunda integración con herramientas Microsoft (Power BI, VS Code) (Chansanchai, 2015). La región Azure México Central (desde 2024) ofrece cumplimiento local y baja latencia (Microsoft, 2024).

- *Facilidad:* Designer *drag-and-drop* y AutoML aceleran proyectos para usuarios no expertos (Chansanchai, 2015).
- *Escalabilidad:* endpoints gerenciados sobre AKS y capacidad de autoscaling horizontal (Azure, 2025).
- *Costos:* descuentos por reservas y Azure Hybrid Benefit resultan atractivos para clientes Windows; sin GPU Azure fue $\sim 3\times$ más caro que AWS en la prueba de 10 h (CloudExpat, 2023).
- *Desventajas:* menos automatización en flujos MLOps avanzados y requiere técnicos familiarizados con Azure Resource Manager (Opala, 2023).

Google Cloud Platform (GCP)

Vertex AI unifica AutoML, entrenamiento custom y *feature store* con acceso a TPUs v5e para acelerar redes neuronales (Barkley, 2023). Google inauguró en 2024 la región Querétaro con energía renovable al 100 % (López & Velázquez, 2024).

- *Facilidad:* interfaz limpia y descuentos automáticos por uso sostenido; fuerte documentación orientada a desarrolladores (Google Cloud, 2023).
- *Escalabilidad:* pipelines CI/CD nativos (Vertex AI Pipelines) y servicio de predicción multi-modelo que optimiza recursos (Barkley, 2023).

- *Costos*: precios por segundo y máquinas preemptibles reducen gastos; en CPU puro Vertex AI costó ~57 % más que AWS para la prueba de 10 h, pero BigQuery + Vertex puede compensar en cargas analíticas (CloudExpat, 2023).
- *Desventajas*: cuota de mercado menor y soporte empresarial con mayor barrera de entrada (Opala, 2023).

IBM watsonx

IBM watsonx (Watson Studio & Watson ML) prioriza AutoAI y flujos visuales (NIX United, 2024). Fue nombrado *Líder* en el Gartner Magic Quadrant 2025 (Aziza & Mortefolio, 2025).

- *Facilidad*: AutoAI genera modelos sin código; SPSS Modeler añade *deep learning* visual (NIX United, 2024).
- *Escalabilidad*: despliegue híbrido via Cloud Pak for Data; menos regiones que los demás y solo un data center latam en Dallas (IBM Cloud, 2025).
- *Costos*: planes empresariales bajo cotización; menos transparente que competencia (Opala, 2023).
- *Desventajas*: ecosistema reducido y precios orientados a corporativos grandes.

Comparación entre plataformas

Factor	AWS	Azure	GCP	IBM wats onx
Cuota de mercado	1.º (≈31 %)	2.º (≈24 %)	3.º (≈11 %)	< 2 %
Región en México	Sí (Qro, 2025)	Sí (CDMX, 2024)	Sí (Qro, 2024)	No (solo Dall as)
AutoML	SageMaker Aut opilot	Azure AutoML	Vertex AI Aut oML	AutoAI

Endpoints serverless	Sí	Sí	Sí	Sí (limitado)
Instancia CPU 4 vCPU /16 GB USD/h	0.17	0.19	0.15	0.13
Soporte GPUs/TPUs	GPUs + Trainium	GPUs	GPUs + TPU	GPUs (limitado)
MLOps nativo	SageMaker Pipelines	Azure ML Pipelines	Vertex AI Pipelines	Watson ML Ops

Recomendación

Ponderando facilidad de adopción, catálogo de servicios avanzados, escala global con región local y coste total de propiedad (incluyendo la prueba comparativa de costos de entrenamiento) **AWS** se mantiene como la opción óptima. SageMaker unifica todo el ciclo de vida de ML, su región mexicana minimiza latencia y residencia de datos, y su estructura de precios flexible (spot, savings plans) permite entrenar el modelo *walking-forward* de una hora con ahorro respecto a Azure y GCP (CloudExpat, 2023). Para organizaciones dependientes del stack Microsoft, Azure sería la segunda mejor elección; si el caso pivota a cargas analíticas masivas o IA generativa específica, GCP podría superar en ciertos sub-escenarios. IBM watsonx se reserva para entornos regulados que demanden gobernanza estricta y flujos *no-code*.

Referencias

- Aziza, B., & Mortefolio, S. (2025, 29 mayo). *IBM named a Leader in the 2025 Gartner® Magic Quadrant™ for Data Science and Machine Learning Platforms*. IBM News. <https://www.ibm.com/new/announcements/ibm-named-a-leader-in-the-2025-gartner-magic-quadrant-for-data-science-and-machine-learning-platforms>
- Azure. (2025). *Virtual Machines Pricing*. <https://azure.microsoft.com/pricing/details/virtual-machines/>
- Barkley, W. (2023, 26 mayo). *Google is Named a Leader in the 2023 Gartner® Magic Quadrant™ for Cloud AI Developer Services*. Google Cloud Blog. <https://cloud.google.com/blog/products/ai-machine-learning/google-named-a-leader-in-the-2023-gartner-magic-quadrant-for-cloud-ai-developer-services-report>
- Business Wire. (2025, 14 enero). *AWS Launches Infrastructure Region in Mexico*. <https://www.businesswire.com/news/home/20250114697961/en/>
- Chansanchai, A. (2015, 20 enero). *Wherever there is data, Azure Machine Learning can make business – and life – better*. Microsoft Stories. <https://news.microsoft.com/features/wherever-there-is-data-azure-machine-learning-can-make-business-and-life-better/>
- CloudExpat. (2023, 13 diciembre). *In-Depth Comparison: AWS SageMaker, Azure ML, and GCP Vertex AI*. CloudExpat Blog. <https://www.cloudexpat.com/blog/sagemaker-azure-ml-gcp-ai-2024/>
- Google Cloud. (2023). *Vertex AI Pricing*. <https://cloud.google.com/vertex-ai/pricing>
- IBM Cloud. (2025). *VPC Virtual Server Pricing*. <https://cloud.ibm.com>
- Krantz, T., Jonker, A., & Gomstyn, A. (2024, 30 octubre). *What is Amazon SageMaker?* IBM Think Blog. <https://www.ibm.com/think/topics/amazon-sagemaker>
- López, E., & Velázquez, J. (2024, 4 diciembre). *¡Hola Mexico! Google Cloud region in Querétaro now open*. Google Cloud Blog.

<https://cloud.google.com/blog/products/infrastructure/google-cloud-announces-41st-cloud-region-in-mexico>

Microsoft. (2024, 7 mayo). *Microsoft launches its first hyper-scale cloud datacenter region in Mexico*. Microsoft News Center LatAm. <https://news.microsoft.com/es-xl/microsoft-launches-its-first-hyper-scale-cloud-datacenter-region-in-mexico/>

NIX United. (2024). *Machine Learning as a Service: Comparison of Cloud Providers*. <https://nix-united.com/blog/machine-learning-as-a-service-comparison-of-cloud-providers/>

Opala, M. (2023, 5 enero). *ML Cloud Platforms Comparison: IBM Watson, Google Cloud, AWS, Azure*. Netguru Blog. <https://www.netguru.com/blog/ibm-watson-vs-google-cloud-vs-aws-vs-azure>

Seitinger, S. (2024, 1 octubre). *AWS recognized as a Leader in the 2024 Gartner Magic Quadrant for Data Science and ML Platforms*. AWS ML Blog. <https://aws.amazon.com/blogs/machine-learning/aws-recognized-as-a-first-time-leader-in-the-2024-gartner-magic-quadrant-for-data-science-and-machine-learning-platforms/>