



Tecnológico de Monterrey

Instituto Tecnológico y de Estudios Superiores de Monterrey

Escuela de Ingeniería y Ciencias

Maestría en Inteligencia Artificial Aplicada

Dra. Grettel Barceló Alonso

Dr. Luis Eduardo Falcón Morales

Materia Proyecto integrador

Avance 7. Resumen ejecutivo

Equipo 11

José Gilberto Amaro Aceves - A01794815

Francisco Antonio Enríquez Cabrera - A01795006

Carlos Eduardo García García - A01795206

15-06-2025

Índice

Síntesis del problema	3
Hallazgos más importantes del análisis exploratorio de datos	4
Hallazgos posteriores al análisis exploratorio.....	4
Modelos generados y razones de la elección del modelo final	9
Walk forward validation.....	12
Solución final.....	15
Recomendaciones clave para implementar la solución	19
Análisis costo – beneficio	27
Recomendación.....	32
Beneficios Potenciales del Proyecto.....	33
Riesgos y desafíos de la solución.....	33
Bibliografía.....	37

Síntesis del problema

El proyecto será realizado para la Cámara Nacional de la Industria Tequilera quien es una institución que ofrece acciones y servicios para fortalecer la cadena productiva, al igual que oportunidades de negocio para mejorar la competitividad de sus miembros.

La cámara ofrece a las empresas la libertad de poder unirse de manera voluntaria en cualquier momento para trabajar por el beneficio del tequila, esto mediante acuerdos y condiciones que permiten la competitividad a nivel nacional e internacional (CNIT, s.f.)

Esta cámara tiene como objetivo “representar, promover y defender los intereses comunes de sus asociados, proponiendo y llevando a cabo las acciones que satisfagan sus necesidades y expectativas para fortalecer el prestigio e imagen de la Industria Tequilera en general y del Tequila en particular” (CNIT, s.f.).

¿Cuál es el problema?

La cámara tiene como propósito de empezar a resolver el problema que tienen las tequileras de saber cuánto producto se tiene que producir al mes para poder cumplir la demanda del mercado, además de resolver el problema de la planeación del cultivo del agave azul que es requerido para su producción.

El principal objetivo es pronosticar las exportaciones totales por tipo de tequila y más específico, pronosticar la exportación de tequila a Estados Unidos, siendo este país el cliente con mayor cantidad de exportaciones de tequila con un estimado de 87% del mercado según los datos obtenidos del CNIT.

¿Por qué es importante resolver este problema?

Permitirá optimizar, balancear la cantidad de agave necesario respecto a la demanda y consumo para la producción del tequila, minimizando mermas y optimizando las ganancias de las tequileras.

¿Cuál es la meta prevista?

La meta prevista es desarrollar tres modelos de ML que realicen tres escenarios posibles sobre la proyección de exportaciones y un cuarto modelo para la proyección del consumo de agave; la

integración de la data implica la implementación de una API para lograr una automatización de la ejecución de los modelos.

Hallazgos más importantes del análisis exploratorio de datos

Durante la fase del análisis exploratorio de datos se realizaron varias actividades, entre ellas fueron la obtención de datos, preprocesamiento y descubrimientos.

Cabe destacar que los datos y todos los artefactos del proyecto se trabajaron en el siguiente repositorio de GitHub:

<https://github.com/FranciscoEnriquez/Proyecto-Modelo-de-Pronostico-de-Exportaciones/tree/main>

Se considera que los siguientes hallazgos fueron los más importantes:

1. Los datos se encuentran alojados en línea y se encuentran disponibles al público general, este se actualiza una vez al mes, los días 8 de cada mes.
2. Dentro de estos distintos reportes se tiene en la mayoría la recurrencia de las mismas características y misma estructura, siendo 3 registros por año, uno por el valor de la subcategoría “Tequila”, otro por el valor de la subcategoría “Tequila 100%” y un último registro del valor total de ese año.
3. No se encontraron valores nulos en ninguna instancia.
4. No hay una correlación fuerte entre ninguna de las características originales.

Hallazgos posteriores al análisis exploratorio

Uno de los hallazgos de información posterior a la etapa de análisis exploratorio fue la realización de la descomposición de los datos temporales lo cual se encontró que en el caso de los datos la división del tradicional 80% de muestra para entrenamiento y 20% de pruebas no funcionaba para estos escenarios.


Como se puede observar (gráficas 1 y 2), se tiene que el 80% de los datos no describen el 20% de los datos restantes, esto siendo un grave problema para los modelos que pueden aprender el comportamiento anterior, pero no tienen manera de saber el siguiente comportamiento.

Se llegó a la hipótesis de que este cambio drástico de comportamiento fue consecuencia de la pandemia del COVID-19, por lo cual se agregó un marcador a esta gráfica para ofrecer un punto de comparativa, cabe destacar que este evento fue en diciembre del 2019, siendo la pandemia oficialmente reconocida en México a finales de febrero del 2020.

El método que se utiliza para hacer la descomposición es `seasonal_decompose` de la paquetería `statsmodels`. La técnica consiste en descomponer los valores observados (serie original) en tres componentes: tendencia, estacionalidad y el residuo o ruido.


La estimación de la tendencia es a través de un suavizado con el uso de ventanas móviles, promediando 12 meses (6 meses anteriores y 6 meses posteriores al mes de la serie). La estacionalidad se calcula en dos etapas: en la primera, se obtiene la diferencia entre el punto original de la serie menos el valor de la tendencia calculada por las ventanas móviles; para la segunda etapa, se hace una agrupación de los valores obtenidos (en la etapa 1) por las estaciones elegidas (en este caso 12) y se calcula el promedio de los años acumulados según el periodo observado. Finalmente, se puede hacer una normalización de los valores estacionales: restando a los valores estacionales el promedio de ellos para cada ventana. Los valores de los residuos son la resta del valor original menos la componente de estacionalidad.

En las gráficas 1 y 2, se muestran las descomposiciones para las series por tipo de tequila. Para el tipo TEQUILA, la tendencia es creciente por etapas, la primera etapa comprende desde el año 1995 hasta poco después del 2000, seguido de una etapa estacionaria (desde 2006 hasta el año 2020), posteriormente hay nuevamente un crecimiento mucho más acelerado que en los primeros años. La estacionalidad es periódica; sin embargo, existe mayor fluctuación en los residuos, en donde a partir del año 2019 la amplitud de los residuos supera la vecindad de ± 2 unidades.



Gráfica 1. Descomposición de la tendencia por Categoría para el tipo *Tequila*: Serie original (superior), gráfica de la tendencia (medio superior), gráfica de la estacionalidad (medio inferior) y gráfica de los residuos (inferior).

La tendencia para el tipo TEQUILA 100% es creciente de forma global, presentando su mayor aceleración de crecimiento a partir del año 2020. La estacionalidad también es periódica, aunque el hallazgo de mayor relevancia está en la gráfica de los residuos (gráfica 2, parte inferior), el ruido detectado supera la vecindad de ± 4 unidades después del año 2020, teniendo en el periodo anterior valores promedio de 1.5 unidades. Este evento es fundamental para entender los resultados obtenidos.




Gráfica 2. Descomposición de la tendencia por Categoría para el tipo *Tequila 100%*: Serie original (superior), gráfica de la tendencia (medio superior), gráfica de la estacionalidad (medio inferior) y gráfica de los residuos (inferior).


En las gráficas 3 y 4, se muestran las descomposiciones de las exportaciones para el país Estados Unidos de América por tipo de tequila. Para el tipo TEQUILA (gráfica 3), la tendencia está descrita por etapas, en donde se muestran crestas y valles globales, el crecimiento más acelera se encuentra en el año 2020 pero con un descenso en el año 2023. La estacionalidad es periódica. Los residuos se encuentran dentro de la banda ± 2 unidades para la mayoría de los puntos antes del año 2020, sin embargo, a partir de esa fecha, hay una mayor fluctuación.

La tendencia para el TEQUILA 100%, es creciente de manera global (gráfica 4, superior), el crecimiento más acelerado es a partir del año 2020, tiene una estacionalidad periódica, y la mayor fluctuación del ruido está en el mismo año que aceleró su crecimiento (gráfica 4, inferior).

Las observaciones realizadas para la serie del país de Estados Unidos de América, son consistentes con las observaciones para la serie global, esto debido a que la participación de este país está es aproximadamente el 87% del total de exportaciones.



Gráfica 3. Descomposición de la tendencia para el país Estados Unidos de América para el tipo *Tequila*: Serie original (superior), gráfica de la tendencia (medio superior), gráfica de la estacionalidad (medio inferior) y gráfica de los residuos (inferior).



Gráfica 4. Descomposición de la tendencia del país Estados Unidos de América para el tipo *Tequila 100%*: Serie original (superior), gráfica de la tendencia (medio superior), gráfica de la estacionalidad (medio inferior, gráfica de los residuos (inferior).

Modelos generados y razones de la elección del modelo final

Al inicio del proyecto se optó por crear un estimador base para poder saber el desempeño de futuros predictores, el cual se realizó usando un **RandomForest**, el cual, a pesar de no ser un modelo especializado en series de tiempo, ofreció un valor al cual empezar a comparar los siguientes modelos.


Más adelante del proyecto se estuvo experimentando con la implementación de distintos modelos tanto especializados y no especializados a problemas de series de tiempo, siendo los no

especializados, al inicio del proyecto, los más sencillos de implementar debido a que los que si son especializados requieren un tratamiento y preprocesamiento especial.


Sin embargo, fue hasta que se empezó a refinar más el preprocesamiento de datos e ingeniería de características, al igual que la implementación de modelos especializados a series de tiempo, como lo es **ARIMAX** y **LSTM** que fue cuando las predicciones empezaron a mejorar significativamente.

ARIMAX fue el primer modelo con el cual se empezó a experimentar con, debido a que su implementación es relativamente sencilla, requiriendo que los datos tengan un índice de fecha y estos cuenten con una frecuencia establecida, además de que permite la integración de valores exógenos en el modelo para ayudar a mejorar las predicciones, aunque en este caso, estos valores fueron metadatos extraídos de la fecha en la ingeniería de características (What Is an ARIMAX Model? , 2023).

LSTM (Long short-term memory), por otro lado, es una red neuronal con una arquitectura diferente a la convencional que se enfoca en capturar dependencias largas y cortas en datos secuenciales, lo cual es ideal para problemas de predicciones en series de tiempo.



Gráfica 5. Primeros resultados de implementación de un LSTM para la serie exportaciones de la categoría TEQUILA.



Gráfica 6. Primeros resultados de LSTM para la serie exportaciones para la categoría TEQUILA 100%.

Después de generar pruebas con estos modelos, se logró mejorar significativamente las predicciones a comparación de otros métodos, sin embargo, estos resultados no fueron tan consistentes como se desea por qué nuevamente se recayó en que los datos de entrenamiento no describían los valores de pruebas por lo cual se decidió en implementar una implementación distinta usando **“Walk forward validation”**.

Walk forward validation

Walk forward validation, en este tipo de validación se puede evaluar el desempeño del modelo en un escenario más realista tal como si fuera (Ahmed Fahad, 2024).

En este tipo de validación se dividen los datos en ventanas de tiempo consecutivas, estas ventanas siendo una ventana de entrenamiento y otra de pruebas.

El objetivo es con este subconjunto de datos de entrenamiento de tamaño N procesar, entrenar y predecir M cantidad de datos, siendo el largo de esta ventana de pruebas la que indica el paso con el que se mueven las predicciones.





Figura 1. Explicación visual de Walk-forward validation: cada fila (fold) representa un segmento de validación secuencial. Las secciones azules corresponden al conjunto de entrenamiento, las rojas al conjunto de validación, las grises a los datos por observar y las blancas a los periodos excluidos; basado en (Börjesson & Singull, 2020)

Con esta nueva implementación se adaptó la solución para poder aprovechar “Walk-forward validation”, entre las cosas que se hicieron fue el determinar el tamaño de la ventana de entrenamiento y de pruebas, en este caso es importante poder incluir un tamaño suficiente para que el modelo usado pueda aprovechar los valores de entrenamiento y poder observar patrones significativos.

En este caso, se decidió optar por ventanas de 36 meses donde después se implementó una ventana corrediza de 24 meses para el entrenamiento del LSTM el cual al final solo tiene como objetivo retornar una sola predicción.

La decisión de que la ventana de predicción fuera de un solo paso fue realizada para brindar un mejor desempeño en los escenarios explicados anteriormente donde al final del historial de valores hay un aumento de ruido significativo, esto a costo de un mayor costo computacional.




Gráfica 7. Experimento de usar un modelo LSTM con “Walk-forward validation” para la serie exportaciones, categoría TEQUILA 100%.

Cabe destacar que como menciona Ahmed Fahad, esta validación tiene tanto ventajas como desventajas, siendo la ventaja más significativa para el problema el capturar patrones evolutivos dentro de los datos, y como mayor desventaja se tiene el alto costo computacional que implica iterar constantemente todos los pasos para conseguir un modelo entrenado.

Solución final

Como ultimo hito en la implementación, fue el integrar tanto el “Walk-forward validation” como la descomposición de los valores temporales, con esta descomposición se crearon dos modelos, uno para la suma de la tendencia y la temporalidad y otro modelo para predecir el ruido, con la suma de estas dos predicciones se consiguió el valor final y se obtuvo una mejor predicción, esto basado en la sugerencia de la asesora Dra. Grettel y en el artículo “A hybrid system based on ensemble learning to model residuals for time series forecasting” donde se experimentan con distintos tipos de predictores de series de tiempo comparado con un modelo hibrido como el que se pretende hacer, dando como resultado que los modelos híbridos tienden a tener una mejor precisión (S. de O. Santos Júnior, S.G. de Mattos Neto, F.L. de Oliveira, & D.C. Cavalcanti, 2023).



Gráfica 8. Implementación de dos modelos para predecir el valor final de la exportación para la categoría TEQUILA 100%.


Como se puede observar, esta implementación da un escenario de aproximación del valor real, no un valor exacto, esto debido a que el ruido encontrado como los residuos en la descomposición del valor temporal es en, cierta parte, impredecible, el modelo para predecir estos valores puede ayudar a encontrar un ligero comportamiento en estos valores, dando como resultado una mejor predicción de los valores.

Este último resultado fue el elegido como el entregable final para el proyecto ya que gracias a la validación de “Walk-forward” se puede tener una mejor solución al problema.


A pesar de la dificultad con la predicción de los picos con frecuencias altas, se utilizó a la transformación de Fourier, para poder estimar y apreciar cómo el modelo *sí está siguiendo el comportamiento de las frecuencias bajas*.

A continuación se presentan las gráficas de la transformación de Fourier que, conforme a los dos modelos de predicción de LSTM: en la gráfica 9 se tiene un panorama más completo del desempeño de los modelos y se ve que en general siguen muy bien las frecuencias bajas de los datos y el modelo batalla en predecir las frecuencias altas tal como se puede ver en la imagen 11 en donde el ruido es tan grande que los picos no los predice. Sin embargo, se ve que, en menor medida, sigue la tendencia de los datos lo cual da una confianza que el modelo está bien entrenado.


Sin embargo, en la gráfica 10 anterior se puede ver que el modelo está siguiendo bastante cerca los valores reales en su comportamiento de la frecuencia. Se considera que a pesar de que las predicciones no son exactas, la predicción sigue muy bien las frecuencias bajas y la tendencia general de los valores, por lo cual se piensa que es un modelo viable para esta problemática.



Gráfica 9. Comparación de la Transformación de Fourier para los valores reales contra las predicciones generadas por el modelo LSTM usando la validación walk-forward. El eje x, representa la frecuencia en ciclos por unidad de tiempo (mensual); mientras que el eje y, muestra la amplitud de la descomposición espectral.



Gráfica 10. Acercamiento de la transformación de Fourier en las frecuencias bajas aplicada a los valores reales (exportaciones, TEQUILA 100%), y las predicciones del modelo LTSM.



Gráfica 11. Acercamiento a las frecuencias altas de la transformación de Fourier (de 3.4-5.2 ciclos por mes valores reales (exportaciones, TEQUILA 100%).

La importancia del uso de la Transformada Rápida de Fourier sobre la serie predicha bajo el modelo es que permite comparar las frecuencias dominantes actuales con las salidas del modelo LSTM. Existe una coincidencia relevante para aquellas frecuencias menores a 0.2, captando los patrones de largo plazo de las componentes estacionales. Para las frecuencias más altas (imagen 5), indican la componente residual (ruido) contienen una mayor variabilidad que no fue completamente “aprendida” por el modelo LSTM.

Recomendaciones clave para implementar la solución

El código ha sido estructurado mediante tres partes principales:

- Un webscrapper para conseguir los datos de la página de los informes del CNIT.
- Una implementación de un DVC pipeline para la preparación y preprocesamiento de los datos.
- Modelado de inteligencia artificial.

Para la implementación de esta solución se recomienda mantener actualizados los datos mediante el uso del Webscrapping una vez al mes ya que esta es la frecuencia con la que estos datos son actualizados en el sitio oficial.

Una vez obtenidos los datos actualizados, correr el pipeline de DVC para obtener los conjuntos de datos divididos ya en sus distintos subconjuntos al igual que la separación del conjunto de entrenamiento y pruebas.

Por último, ejecutar el entrenamiento del modelo con los nuevos datos para poder tener siempre el mejor modelo disponible y evitar el “data drift”.




Figura 2. Diagrama de la estructura general del código.

El código funciona mediante un DVC pipeline que está estructurado en distintos archivos, estos siendo:

- Pasos/Scripts
- Configuraciones
- Parámetros

Para DVC, existen dos archivos importantes que es el de configuración del pipeline y otro el de parámetros.

El de configuración indica que comando de consola va a usar para ejecutar los códigos, que dependencias tienen estos pasos del pipeline y que parámetros son los que tiene que observar para cambios al igual que las salidas de estos pasos.

Por otro lado, se maneja un segundo archivo yaml para los parámetros que se usan, DVC junto a las configuraciones de dependencias y parámetros maneja un control de versiones interno el cual permite diferenciar cuando uno de estos cambia y si un paso requiere este valor y nota un cambio fuerza a que este paso se vuelva a ejecutar. Este archivo de parámetros simplemente es una manera

en la cual se listan los parámetros y que se pueden modificar en cualquier momento y desarrollar experimentos con ellos.

```
stages:
  prepare:
    cmd: python pipeline/prepare.py
    deps:
      - data/consolidado_consumodeagavetotal.csv
      - data/consolidado_exportaciones_pais.csv
      - data/consolidado_exportacionestotalcategoria.csv
      - data/consolidado_exportacionestotalforma.csv
      - data/consolidado_producciontotaltequila.csv
    params:
      - prepare.seed
      - prepare.train_split
      - prepare.files
    outs:
      - data/pipeline/prepared
  preprocessing:
    cmd: python pipeline/preprocess.py data/pipeline/prepared data/pipeline/preprocessed
    deps:
      - data/pipeline/prepared
    params:
      - preprocess.target
      - preprocess.low_var
      - preprocess.high_corr
      - preprocess.seed
      - preprocess.files
  train_and_predict:
    cmd: python pipeline/train_and_predict.py data/pipeline/prepared data/pipeline/train_and_predict
    deps:
      - data/pipeline/prepared
    params:
      - wf_train_and_predict.walking_forward.window_size
      - wf_train_and_predict.walking_forward.predict_window
      - wf_train_and_predict.months_to_predict
      - wf_train_and_predict.low_var
      - wf_train_and_predict.high_corr
      - wf_train_and_predict.export_graphs
      - wf_train_and_predict.files
```

Figura 3. Estructura del archivo dvc.yaml

```

version_label: "0.1"
preprocessing:
  CONTINENTE_MAP:
    "ESTADOS UNIDOS DE AMERICA": "America"
    "CANADA": "America"
    "BRASIL": "America"
    "ALEMANIA": "Europa"
    "FRANCIA": "Europa"
    "REINO UNIDO": "Europa"
    "ESPAÑA": "Europa"
    "CHINA": "Asia"
    "JAPON": "Asia"
  LOW_VAR_THRESHOLD: 0.01
  HIGH_CORR_THRESHOLD: 0.95
prepare:
  train_split: 0.80
  seed: 42
  files:
    - path: "consolidado_exportaciones_pais.csv"
      subcategoria_col: "Categoria"
    - path: "consolidado_exportacionestotalcategoria.csv"
      subcategoria_col: "SubCategoria"
preprocess:
  target: "Valor"
  low_var: 0.01
  high_corr: 0.95
  seed: 42
  files:
    - file_name: "exportaciones_pais"
      subcategoria_col: "Categoria"
    - file_name: "exportacionestotalcategoria"
      subcategoria_col: "SubCategoria"
wf_train_and_predict:
  walking_forward:
    window_size: 36
    predict_window: 1
  months_to_predict: 84
  low_var: 0.01
  high_corr: 0.95
  export_graphs: true
  files:
    - "exportaciones_pais"
    - "exportacionestotalcategoria"
mlflow:
  run_name: "Run for {model}"
  experiment_name: "TequilaExportaciones"
  tracking_uri: "http://127.0.0.1:5000"

```

Figura 4. Archivo de parámetros YAML (params.yaml)

Después de estas configuraciones se tiene lo que son los pasos que se encuentran dentro de las configuraciones de dvc.yaml.




Figura 5. Estructura de archivos del pipeline.

Tal como se muestra en la figura 5, la estructura es bastante sencilla y se puede tratar como sea necesario, en este caso se dividieron en los pasos necesarios para llegar a la conclusión del modelo.

El archivo de “prepare.py” se enfoca meramente en la división de los datos crudos, se eliminan las filas con los totales, se separan en distintos datasets las subcategorías para obtener datasets con un solo registro por mes, logrando una consistencia “temporal” en los datos, al igual que hacer la división de los datos en distintos archivos, tanto como uno de pruebas, otro de entrenamiento y al final uno completo, esto brinda una mayor libertad a la hora de querer manejar estos datos.

Por otro lado, el archivo de “preprocess.py” es donde se realiza todo el preprocesamiento de los datos de una manera organizada, en este se separaron las funciones para ser reusadas de ser necesario al importarlas en otro archivo y en este archivo directamente se trabajó con los archivos generados en “prepare.py”.

Al final se tiene el archivo de “train_and_predict.py” que es el archivo principal para el proyecto, donde se hace la predicción de los valores. En este caso se asignó la dependencia con la salida de “prepare.py” ya que no se manejó el tradicional Split de entrenamiento-pruebas tal como se explicó con anterioridad.

Sin embargo, esto no implica que el archivo de “preprocess.py” no sea importante ya que de este mismo archivo se importó la función de feature_engineering que ayuda a hacer el preprocesamiento de las ventanas de entrenamiento y pruebas y con este se puede trabajar en distintas maneras bajo el mismo código y sin necesidad de estar manejando múltiples libretas, solo archivos con propósitos bien definidos en el desarrollo del modelo.

Por último, se cuenta con lo que son las salidas de estos archivos, que son manejados de la misma manera en la cual fueron realizados los pasos, en subcarpetas bajo el mismo nombre del paso para una mayor claridad y consistencia.




Figura 6. Estructura de archivos de salida del pipeline de DVC.


Para la ejecución del pipeline, solo se debe tener las librerías necesarias instaladas en el entorno y hacer uso del comando:

dvc repro


O en caso de ser necesario, se puede forzar una ejecución total de los pasos usando el comando:

dvc repro -f


Una vez ejecutado el pipeline se pueden observar los resultados de dos formas, a través de gráficas y a través de un archivo CSV con los valores predichos tal como se muestra en las siguientes graficas.




Gráfica 12. Proyección de las exportaciones de tequila por país (Estados Unidos) para los siguientes 7 años.



Gráfica 13. Proyección de las exportaciones de tequila 100% de agave por país (Estados Unidos) para los siguientes 7 años.



Gráfica 14. Proyección de las exportaciones de tequila por categoría para los siguientes 7 años.



Gráfica 15. Proyección de las exportaciones de tequila 100% de agave por país (Estados Unidos) para los siguientes 7 años.

Una vez explicado esto, el código fue estructurado de una manera con la cual solo se tienen que listar el resto de los archivos no trabajados para también implementar predicciones para los mismos, al igual que otros países y, aunque con un poco más de trabajo requerido, se pueden adaptar lo suficiente para aumentar la granularidad de estas divisiones dentro de las clases de tequila dentro del archivo de exportaciones de tequila por país.

Análisis costo – beneficio

En la siguiente sección se enumeran todos los costos incurridos (relacionados con la adquisición de datos, el uso de servidores, servicios en la nube, y cualquier hardware o software específico necesario) divididos por fase de la metodología CRISP-ML para dos plataformas recomendadas Google Cloud Platform (GCP) y Amazon Web Services (AWS).

Así mismo se identifican los costos esperados para la operación y mantenimiento del modelo.

En la tabla 1, se presenta una estimación de costos por etapa de la metodología CRISP-ML, bajo el escenario de implementación bajo la plataforma GCP con dos modelos de servicios PaaS (Plataforma como servicio) y SaaS (Software como servicio). Las diferencias principales es el alcance de los modelos sobre la gestión de los recursos.

Etapas CRISP-ML	SaaS (Vertex AI) Gestionado	PaaS (GCP) Autogestionado	Referencia
1. Entendimiento del negocio y de la data.	Suscripción a herramientas como Looker, BigQuery Notebook gestionado: ~ \$0.10/h	Compute Engine n1-standard: ~\$0.15/h + Cloud Storage ~\$0.026/GB por mes.	https://cloud.google.com/vertex-ai/pricing
2. Adquisición y Entendimiento de la data.	BigQuery UI: \$5/TB procesado + \$0.02/GB por mes almacenamiento	Dataflow: \$0.056/vCPU·h + \$0.0035/GB·h RAM + \$0.011/GB shuffle	https://cloud.google.com/bigquery/pricing
3. Preprocesamiento de la data.	Incluido en plataformas como Vertex AI Pipelines, BigQuery ML.	Scripts ETL en Dataflow o Cloud Functions. Costo de instancias + procesamiento	https://cloud.google.com/dataflow/pricing
4. Modelado	AutoML con GPU (Tesla T4): ~\$0.35/h + VM ~\$0.38/h	Instancias con GPU configuradas manualmente. Misma tarifa por hardware	https://cloud.google.com/vertex-ai/pricing#training_pricing

5. Evaluación del Modelo	SHAP/LIME integrados en Vertex AI. Costo incluido	Ejecución en n1-standard (~\$0.10–0.15/h) + librerías open source	https://cloud.google.com/vertex-ai/docs/explainable-ai/overview
6. Deployment	Vertex AI endpoint: ~\$0.10/h por nodo + autoscaling incluido	Cloud Run / GKE: ~\$0.10–0.15/h por instancia + tráfico adicional	https://cloud.google.com/vertex-ai/pricing#prediction_pricing
7. Monitoreo y Mantenimiento	Incluido: logging, drift detection, auditoría automática	Stack propio (MLFlow, Prometheus). Logging ~\$0.02/GB por mes + horas hombre	https://cloud.google.com/logging/pricing

Tabla 1. Ejemplo de uso: Comparativa de costos en la plataforma GCP usando los modelos SaaS (Software as a Service) y PasS (Platform as a Service). Los valores están expresados en dólares estadounidenses (USD) y están sujetos a cambios según el tipo de instancia, región y volumen de procesamiento. En la tabla 2, se ejemplifican los desgloses del costo estimado de las probables componentes a implementar bajo la metodología CRISP-ML.

Componente	Saas (Vertex AI)	PasS (GCP autogestionado)	Referencia
Notebook /EDA	100 horas x \$0.10 = \$10	100 h x \$0.15 = \$15	Vertex AI Workbench: n1-standard-4 ≈ \$0.10/h

			https://cloud.google.com/vertex-ai/pricing
Bigquery + Storage	2 TiB de consulta = \$10 500 GB de almacenamiento activo = \$10	2 TiB de consulta = \$10 500 GB de almacenamiento activo = \$10	BigQuery Query: \$5/TiB consultado; Storage: \$0.02/GB·mes https://cloud.google.com/bigquery/pricing
ELT (Dataflow)	Incluido (en SaaS no se factura separado)	100 h x 2 vCPU = 200 vCPU·h x \$0.056 = \$11.2	https://cloud.google.com/dataflow/pricing
Modelado con GPU	10 h x (\$0.35 + \$0.38) = \$7.3	10 h x (\$0.35 + \$0.38) = \$7.3	GPU Tesla T4 + n1-standard-4 VM https://cloud.google.com/vertex-ai/pricing#training_pricing
Inferencia	100 h x \$0.10 = \$10	100 h x \$0.15 = \$15	Vertex AI endpoint vs. Cloud Run / GKE
Monitoreo y logging		~50 GB logs x \$0.02 = \$1	Operations suite logging https://cloud.google.com/logging/pricing
Total Estimado	≈ \$37/mes (USD)	≈ \$49/mes (USD)	

Tabla 2. Desglose del cálculo estimado de costos mensuales usando los servicios SaaS y PaaS, bajo la metodología CRISP-ML. Los valores están expresados en dólares estadounidenses (USD) y corresponden a un escenario de uso moderado. Las tarifas fueron obtenidas de fuentes oficiales

de Google Cloud Platform. Para una estimación precisa y actualizada, se recomienda utilizar el GCP Pricing Calculator.

Otra plataforma en la nube adecuada para la ejecución del proyecto es Amazon Web Services (AWS), en la tabla 3, se muestran

Etapas CRISP-ML	AWS (SageMaker / Gestionado)	Referencia
1. Entendimiento del negocio y de la data.	SageMaker Studio Notebooks (~\$0.05/h, ml.t3.medium)	https://aws.amazon.com/es/sagemaker-ai/studio/
2. Adquisición y Entendimiento de la data.	Data Wrangler + Glue Data Catalog (incluido en Studio)	https://docs.aws.amazon.com/sagemaker/latest/dg/data-wrangler.html
3. Preprocesamiento de la data.	SageMaker Pipelines + EMR (según uso, ~\$0.11/vCPU·h)	https://aws.amazon.com/es/sagemaker-ai/pipelines/
4. Modelado	AutoPilot, GPU/Trainium (25–37%)	https://cloudexpat.substack.com/p/cloudexpat-benchmarking-2023

	menos que GCP)	
5. Evaluación del Modelo	AutoPilot explainers (SHAP), ML Lineage (sin cargo extra)	https://docs.aws.amazon.com/sagemaker/latest/dg/whatis.html
6. Deployment	Endpoints serverless (~\$0.0005 por invocación)	
7. Monitoreo y Mantenimiento	Model Monitor + CloudWatch (~\$0.03/GB logs)	https://docs.aws.amazon.com/sagemaker/latest/dg/model-monitor.html

Tabla 3. Estimación de las capacidades y costos de AWS SageMaker, basados en la metodología CRISP-ML. Los enlaces proporcionan acceso a documentación oficial y estudios comparativos de costos en dólares americanos.

Recomendación

Ponderando facilidad de adopción, catálogo de servicios avanzados, escala global con región local y coste total de propiedad (incluyendo la prueba comparativa de costos de entrenamiento) AWS se mantiene como la opción óptima. SageMaker unifica todo el ciclo de vida de ML, su región mexicana minimiza latencia y residencia de datos, y su estructura de precios flexible (spot, savings plans) permite entrenar el modelo walkingforward de una hora con ahorro respecto a GCP

(CloudExpat, 2023). Para cargas analíticas masivas o IA generativa específica, GCP podría superar en ciertos subescenarios.

Beneficios Potenciales del Proyecto

A continuación, se enuncian algunos de los beneficios potenciales que destacaron del proyecto desde la perspectiva operativa, optimización de recursos y toma de decisiones.

1. **Perspectiva Operativa:** permite establecer una correlación analítica entre la producción y exportación con la demanda estimada a nivel país y categoría, reduciendo sobrecostos por inventario o capacidad de acuerdo con la estacionalidad.
2. **Perspectiva de Optimización de recursos:** es posible anticipar los volúmenes para ciertos periodos identificados en donde las variables exógenas entren poco en juego. Las desviaciones respecto a la estacionalidad esperado también es una métrica para detectar eventos de tipo exógeno por ejemplo aquellos cambios disruptivos en el comportamiento de los clientes y de cambios en políticas comerciales.
3. **Perspectiva en la toma de decisiones:** El proyecto provee un marco de análisis predictivo estableciendo métricas analíticas de confiabilidad sustentas en la información que puede inferir desde la data. La trazabilidad de los datos y el monitoreo de las tendencias del modelo con nuevos datos permites anticipar incumplimientos e identifican nuevas oportunidades a nivel país con crecimiento sostenido.

Riesgos y desafíos de la solución

¿Cuáles son los riesgos o desafíos potenciales de la solución propuesta?

El proyecto enfrenta cuatro frentes de riesgo estrechamente relacionados. Primero, la calidad y vigencia de los datos: después de la pandemia la serie cambió de forma abrupta y, si vuelve a hacerlo, el modelo exigirá re-entrenamientos más frecuentes; además, basta que el CNIT retrase la publicación o altere el formato de su portal para que el “scraper” deje huecos y las predicciones se degraden. Segundo, la seguridad del flujo de información: un atacante podría insertar valores falsos en la fuente o enviar consultas maliciosas al endpoint para forzar salidas absurdas o incluso reconstruir el LSTM, erosionando la ventaja competitiva. Tercero, la confianza en los resultados:

los picos del componente residual siguen siendo difíciles de anticipar, lo que puede inducir sobre- o sub-producción de agave, y la arquitectura híbrida —percibida como “caja negra”— privilegia el mercado estadounidense, lo que genera dudas internas sobre sesgo y explicabilidad. Por último, el cumplimiento normativo: la automatización y redistribución de datos públicos puede requerir acuerdos explícitos con el CNIT; procesar la información fuera de México o sin trazabilidad completa pondría al proyecto en conflicto con futuras exigencias de soberanía de datos y regulaciones de IA confiable.

Clasificación de los riesgos identificados en las categorías de riesgos asociados a datos, ataques AI/ML, prueba y confianza y cumplimiento

Categoría AIRS	Riesgo / desafío	Descripción concreta	Efecto en costos y beneficios
1. Datos – limitaciones de aprendizaje	Deriva de datos (data drift)	Cambios estructurales en la demanda tras eventos disruptivos (p. ej. fin de pandemia, variaciones arancelarias).	Re-entrenamientos más frecuentes → ↑ horas-GPU, ↑ horas de ingeniería.
	Variables exógenas limitadas	El modelo se apoya casi sólo en información temporal; no integra precio del agave, tipo de cambio o campañas de marketing.	Mayor error de pronóstico en escenarios fuera de patrón → decisiones subóptimas.
1. Datos – calidad	Errores de captura / formato	El CNIT podría cambiar etiquetas, agregar columnas o alterar el layout HTML; el scraper fallaría o introduciría valores mal alineados.	Retrabajo de limpieza, paros del pipeline y posible degradación de métricas.

	Lag de actualización	El reporte oficial se publica el día 8 de cada mes; un retraso rompe la ventana “walk-forward”.	Huecos temporales → re-ejecuciones extra y posible sobre-coste de inventario.
2. Ataques AI/ML – privacidad y envenenamiento	Envenenamiento de datos	Manipulación del sitio origen (o “man-in-the-middle”) que introduce registros adulterados.	Pronósticos sesgados → sobre-/sub-producción y pérdida económica.
	Entradas adversas	Solicitudes a la API con fechas fuera de rango o volúmenes extremos para probar límites numéricos.	Caídas del servicio, inferencias absurdas, gasto de soporte.
2. Ataques AI/ML – extracción de modelos	Model-stealing	Uso intensivo del endpoint para recrear parámetros del LSTM híbrido.	Pérdida de ventaja competitiva; necesidad de rotar claves / añadir rate-limiting.
3. Pruebas y confianza – salida incorrecta	Alta varianza del componente residual	Picos ($> \pm 4$ desv. est.) no capturados por el modelo, aun tras la fase de ruido.	Sobre-/sub-estimación de existencias de agave → impacto directo en costos.
3. Pruebas y confianza – falta de transparencia	“Caja negra” del LSTM + híbrido	Complejidad del modelo dificulta explicar resultados a directivos o auditores.	Reticencia a adoptar la solución, o necesidad de invertir en herramientas de interpretabilidad.
3. Pruebas y confianza – sesgos	Enfoque en EE. UU.	Optimizar para el mercado de EE. UU. ($\approx 87\%$) puede	Pérdida de oportunidades de exportación;

		subrepresentar otras regiones emergentes.	decisiones de marketing desbalanceadas.
4. Cumplimiento – políticas y licencias	Derechos de redistribución de datos	Aunque los informes son públicos, la automatización y republicación pueden requerir permiso escrito del CNIT.	Multas o suspensión del acceso; costos legales.
	Residencia soberana de datos	Procesamiento en nubes fuera de México podría violar lineamientos sectoriales sobre agro-industria estratégica.	Obligación de migrar infraestructura, sanciones regulatorias.
	Auditoría y trazabilidad	Si DVC o el pipeline no guardan metadatos de cada ejecución, no se puede reconstruir una predicción histórica.	No conformidad con normas ISO/FINREP; tiempo extra en análisis forense.
	Normativas emergentes de IA confiable	EU AI Act, posibles regulaciones mexicanas de IA exigirán pruebas de robustez y explicabilidad formal.	Gastos adicionales en validación, documentación y certificaciones.

Bibliografía

Ahmed Fahad, I. (28 de October de 2024). *Understanding Walk Forward Validation in Time Series Analysis: A Practical Guide*. Obtenido de Medium: <https://medium.com/@ahmedfahad04/understanding-walk-forward-validation-in-time-series-analysis-a-practical-guide-ea3814015abf>

Artificial Intelligence/Machine Learning Risk & Security Working Group (AIRS) (2024). Artificial Intelligence Risk & Governance. AI at Wharton. <https://ai.wharton.upenn.edu/white-paper/artificial-intelligence-risk-governance>

Börjesson, L., & Singull, M. (September de 2020). Forecasting Financial Time Series through Causal and Dilated Convolutional Neural Networks. *Entropy*. doi:10.3390/e22101094

CloudExpat. (2023, 13 diciembre). InDepth Comparison: AWS SageMaker, Azure ML, and GCP Vertex AI. CloudExpat Blog. <https://www.cloudexpat.com/blog/sagemaker-azure-ml-gcp-ai-2024/>

CNIT. (s.f.). *Cámara Tequilera*. Obtenido de Cámara Nacional de la Industria Tequilera: <https://www.cnit.org.mx/camara-tequilera/>

CNIT. (s.f.). *Página de inicio - Cámara Nacional de la Industria Tequilera*. Obtenido de Cámara Nacional de la Industria Tequilera: <https://www.cnit.org.mx/>

Google Cloud. (2023). Vertex AI Pricing. <https://cloud.google.com/vertex-ai/pricing>

What Is an ARIMAX Model? . (21 de April de 2023). Obtenido de 365datascience: <https://365datascience.com/tutorials/python-tutorials/arimax/>