

Modelo de Pronóstico de Exportaciones de Tequila

Cámara Nacional de la Industria Tequilera (CNIT)

Presenta(n):

- García García Carlos Eduardo
- Amaro Aceves José Gilberto
- Enríquez Cabrera Francisco Antonio

Asesor: Dra. Grettel Barceló Alonso

Patrocinador(es): Lic. Felipe Villalobos Serrano

Resumen

Para la Cámara Nacional de la Industria Tequilera (CNIT) se construyó un **sistema predictivo** que **combina modelo de redes neuronales** con una **descomposición temporal** de series de tiempo.

La solución, alimentada por los reportes mensuales que el CNIT publica cada día 8, **genera pronósticos** actualizados sobre el **volumen exportado de tequila** —especialmente hacia Estados Unidos, que concentra casi nueve de cada diez litros vendidos al exterior— y sobre la cantidad de agave que será necesaria para cubrir esa demanda.

El **modelo se ejecuta** dentro de un **pipeline controlado** por un **Control de Versiones de Datos (DVC*)** y puede reentrenarse fácilmente con el uso de un comando cuando llegan nuevos datos.



*DVC: Data Version Control (Control de Versiones de Datos).

Objetivo del proyecto

El **objetivo** principal es **anticipar** la cantidad **total de tequila** que será **exportada**, tanto a nivel global como hacia **Estados Unidos**, principal destino de exportación al concentrar aproximadamente el **87%** del total.

Los modelos desarrollados permitirán a la Cámara y a sus partes interesadas optimizar y equilibrar la cantidad de agave requerida frente a la demanda y el consumo, minimizando desperdicios y maximizando las ganancias de las casas tequileras.

Introducción

La **industria tequilera** agrupa empresas que deben **decidir** con meses y hasta años de **antelación** cuánto destinarán a **producción** y cuánto agave sembrarán para abastecerla (Cárdenas, 2022).

La **pandemia alteró** bruscamente los **patrones** del mercado, de manera que los **métodos clásicos (división 80/20)** dejaron de ser fiables debido a que la muestra de entrenamiento ya no describe la muestra de pruebas.

Gracias a esto, se requiere complementar con **técnicas adicionales** para la **exploración y predicción** de **tendencias variantes**.




Figura 1. Gráfica de la descomposición del total de exportación a Estados Unidos sobre el tiempo.

Marco de trabajo CRISP-ML

Fase CRISP-ML	
1. Business & Data Understanding	El CNIT necesita pronosticar exportaciones mensuales de Tequila 100 % y se evaluaron los datos del CRT (1995-2025) confirmando estacionalidad y cero valores faltantes.
2. Data Preparation	Con prepare.py se filtraron filas, dejamos solo Tequila 100 %, se partieron 80/20 y, con preprocess.py, se añadió fecha, seno/cos mes, dummies y escalado, guardando todo versionado con DVC.
3. Model Building	Modelo híbrido: descomposición aditiva + dos redes LSTM (una para tendencia-estacionalidad y otra para residuo) entrenadas en ventanas deslizantes de 36 → 1 mes.
4. Evaluation	Walk-forward muestra MAE/RMSE estables; la FFT confirma que el modelo replica los ciclos de 6-12 meses y suaviza el ruido.
5. Deployment	Pipeline reproducible con dvc repro; artefactos y Docker listos para lanzarse en AWS SageMaker o local.
6. Monitoring & Maintenance	Próximo paso: Evidently/NannyML para deriva y re-entrenos mensuales; se planifica granularidad por estado y prueba de modelos ligeros (N-BEATS, TFT).

Hallazgos del EDA*

- Los **datos** se encuentran **alojados** en **línea** y se encuentran disponibles al público general y estos se actualizan los días 8 de cada mes.
- Dentro de estos distintos reportes se tiene, en la mayoría, la recurrencia de las **mismas características** y misma **estructura**, siendo 3 registros por año, uno por el valor de la subcategoría “Tequila”, otro por el valor de la subcategoría “Tequila 100%” y un último registro del valor total de ese año.
- **No** se encontraron **valores nulos** en ninguna instancia.
- **No** hay una **correlación fuerte** entre ninguna de las **características originales**.

Hallazgos del EDA*

Datasets **antes** de preparación y preprocesamiento...

Dataset	Columnas	Registros
consolidado_exportacionestotalcategoria	5	1,089
consolidado_exportaciones_pais	8	64,281

Columnas de consolidado_exportacionestotalcategoria: 'Subcategoria', 'Year', 'Valor', 'AñoArchivo' y 'Mes'

Columnas de consolidado_exportaciones_pais: 'NombrePais', 'Total_Pais_Mes', 'Categoria', 'Total_Categoria_Mes', 'Clase', 'Litros 40 % Alc. Vol', 'AñoArchivo' y 'Mes'

Datasets **después** de preparación y preprocesamiento...

Dataset	Columnas	Registros
exportacionestotalcategoria_teq100	16	363
exportaciones_pais_teq100	16	339

Columnas: 'Valor', 'Year', '**Month_sin**', '**Month_cos**', 'Mes_Aug', 'Mes_Dec', 'Mes_Feb', 'Mes_Jan', 'Mes_Jul', 'Mes_Jun', 'Mes_Mar', 'Mes_May', 'Mes_Nov', 'Mes_Oct' y 'Mes_Sep'

Hallazgos del EDA*

En ambos datasets, se observó que:

- **"Valor"** tiene una correlación muy alta con **"Year"** (≈ 0.87 – 0.88) y con **"década"** (≈ 0.85 – 0.96).

Refleja la tendencia general al alza a lo largo del tiempo.

- La correlación de **"Valor"** con los indicadores cíclicos **"Month_sin"** y **"Month_cos"** es prácticamente nula ($< |0.05|$).

Indica que la estacionalidad pura no explica directamente los niveles absolutos de exportación.




Figura 2. Mapa de calor de las características de los datos en exportaciones totales y Estados Unidos.

Hallazgos del EDA*

- Las variables: "**Trend**", "**Year**" y "**Decada**" son altamente significativos ($p \ll 0.001$).

Estas tres variables **capturan** la **evolución a largo plazo** de la serie y explican la mayor parte de la varianza.

- Residuo** aparece en cuarto lugar con $p \approx 0.001$ – 0.005 .

Aunque es menos potente que la tendencia pura, aporta **información** adicional sobre las fluctuaciones no estacionales.




Figura 3. Significancia de las variables exploradas.

Hallazgos del EDA*

En ambos casos la prueba χ^2 dice que:

- "Década" – **p-value $\ll 0.05$** en los dos conjuntos $\Rightarrow$ **existe una asociación estadísticamente significativa** entre la década y el nivel de exportaciones. Es decir, las diferencias por década sí aportan información relevante.
- "Trimestre" – **p-value $\gg 0.05$** en ambos casos $\Rightarrow$ **no hay evidencia de asociación** entre el trimestre del año y el volumen de exportaciones. Esa variable no parece aportar información útil.




Figura 4. Pruebas Chi-square.

Metodología

Con el objetivo de abordar la problemática central, se optó por implementar un **modelo híbrido de pronóstico**, respaldado por estudios como *“A hybrid system based on ensemble learning to model residuals for time series forecasting”* (De o Santos Júnior et al., 2023); los cuales demuestran que este tipo de enfoques tiende a ofrecer mayor precisión al combinar diferentes predictores.

La estrategia híbrida permite **descomponer** el problema en **dos componentes**:

- La primera, **modela la tendencia y la estacionalidad** de la serie temporal,
- La segunda, se enfoca en capturar el **componente residual o ruido**, especialmente útil cuando se presentan fluctuaciones de alta frecuencia.

La **predicción final** se obtiene al **sumar** las salidas de **ambos modelos**.

Adicionalmente, para **mitigar** el **impacto** de la **evolución temporal** en los datos y **mejorar la capacidad de adaptación** del modelo a nuevos patrones, se implementó una **validación del tipo walk-forward**, la cual permite ajustar los parámetros de forma continua conforme se incorporan nuevos datos (Fahad, 2024).

Metodología – Walk-Forward

Walk forward validation, en este tipo de validación podemos evaluar el desempeño de nuestro modelo en un escenario más realista tal como si fuera producción (Ahmed Fahad, 2024).

En este tipo de validación se dividen los datos en ventanas de tiempo consecutivas, estas ventanas siendo una ventana de entrenamiento y otra de pruebas.




Figura 7. Explicación visual de Walk-forward validation: cada fila (fold) representa un segmento de validación secuencial. Las secciones azules corresponden al conjunto de entrenamiento, las rojas al conjunto de validación, las grises a los datos por observar y las blancas a los periodos excluidos; basado en (Börjesson & Singull, 2020)

Metodología - DVC pipeline

La implementación final implicó el uso de un **DVC* pipeline** para la **automatización parcial** del proyecto y el **control** de futuros **experimentos**.




Figura 8. Boceto general de la arquitectura del proyecto.

*DVC: Data Version Control (Control de Versiones de Datos).

Modelos de Machine Learning (ML) Experimentados y Métricas de Desempeño

Tipo / Enfoque	Modelo	MAE	RMSE	R ²
Red Neuronal Recurrente + Descomposición Estacional	LSTM A+B (Walk-Forward)	0.85	1.45	0.96
Ensamble de Árboles (Bagging)	ExtraTrees	1.77	2.41	-0.41
Ensamble de Árboles (Boosting)	GradientBoosting	1.86	2.51	-0.50
Ensamble de Árboles (Boosting)	HistGradientBoosting	1.92	2.59	-0.52
Árbol de Decisión	DecisionTree	2.11	2.82	-0.74
Vecinos Cercanos (Geométrico)	KNeighbors	2.25	2.75	-0.20
Regresión Lineal (L1)	Lasso	2.38	2.89	-0.65
Máquina de Soporte Vectorial	SVR	2.60	3.33	-0.68
Regresión Lineal (L2)	Ridge	3.51	4.14	-4.08
Regresión Lineal	LinearRegression	3.52	4.15	-4.10
Modelo Base (Media/Constante)	Dummy	3.54	4.07	-1.79




Figura 11. Gráfica con las estadísticas de los modelos a lo largo del proyecto.

- Notas
- los val
 - B_a
 - B_c
 - G_c)
 - **Regresión L1/L2** (Lasso y Ridge): ajusta combinaciones lineales penalizando la complejidad del modelo (L1 reduce coeficientes a cero, L2 los encoge).
 - **SVR** (Support Vector Regression): encuentra una función que predice dentro de un margen de tolerancia, maximizando la separación de errores.
 - **Modelo Base** (Dummy): predice un valor constante (como la media) sin usar variables predictoras.
 - **LSTM** (Long Short-Term Memory) Tipo de red neuronal recurrente (RNN) diseñada para modelar secuencias y datos temporales.

Resultados

Se obtuvieron predicciones positivas en la validación del modelo, por otro lado, en la predicción a 7 años vemos como el comportamiento del LSTM aprende el ruido al final y eventualmente lo va olvidando.

Al mismo tiempo, se obtuvo un sistema semiautomatizado para la obtención, procesamiento y predicción de nuestros diferentes conjuntos de datos.




Figura 9. Walk forward validation




Figura 10. Predicción a 7 años usando Walk forward

- **LSTM** (Long Short-Term Memory) Tipo de red neuronal recurrente (RNN) diseñada para modelar secuencias y datos temporales.

Resultados – Consumo de agave (Tequila).




Figura 14. Walk forward validation. Consumo de agave.




Figura 15. Walk forward. Predicción del Consumo de agave en los siguientes 7 años.

Conclusiones

La **integración** de un **modelo híbrido** junto con las distintas estrategias implementadas en este proyecto mostraron ser una solución prometedora para el problema de la predicción de la exportación del tequila.

Sin embargo, el modelo sigue siendo sensible a cambios tan bruscos en el mercado como lo fueron las políticas de los aranceles que sucedieron a principios del año.

Trabajo futuro

Los siguientes pasos se centran en profundizar la robustez y el alcance del sistema:

- Desplegar un monitor de deriva que evalúe de forma continua la distribución de los nuevos datos y dispare alertas automáticas cuando el rendimiento del modelo se deteriore.
- Incrementar la granularidad de los pronósticos hasta nivel estado, marca o canal de venta, con el fin de ofrecer recomendaciones más accionables.
- Explorar arquitecturas más ligeras—por ejemplo, N-BEATS o Temporal Fusion Transformer—que permitan re-entrenar cada ciclo mensual en cuestión de minutos sin sacrificar precisión.
- Diagnosticar el tamaño del desfase entre predicción y valores actuales.

Referencias

Ahmed Fahad, I. (28 de October de 2024). *Understanding Walk Forward Validation in Time Series Analysis: A Practical Guide*. Obtenido de Medium:

<https://medium.com/@ahmedfahad04/understanding-walk-forward-validation-in-time-series-analysis-a-practical-guide-ea3814015abf>

Artificial Intelligence/Machine Learning Risk & Security Working Group (AIRS) (2024). Artificial Intelligence Risk & Governance. AI at Wharton. <https://ai.wharton.upenn.edu/white-paper/artificial-intelligence-risk-governance>

Börjesson, L., & Singull, M. (September de 2020). Forecasting Financial Time Series through Causal and Dilated Convolutional Neural Networks. *Entropy*. doi:10.3390/e22101094

Cárdenas, E. P. (2022). Innovación en la industria del tequila: historia y tendencias. *Carta económica regional*, 34(129), 93-121. <https://doi.org/10.32870/cer.v0i129.7830>

CloudExpat. (2023, 13 diciembre). InDepth Comparison: AWS SageMaker, Azure ML, and GCP Vertex AI. CloudExpat Blog. <https://www.cloudexpat.com/blog/sagemaker-azure-ml-gcp-ai-2024/>

CNIT. (2024). *Cámara Tequilera*. Obtenido de Cámara Nacional de la Industria Tequilera: <https://www.cnit.org.mx/camara-tequilera/>

CNIT. (2024). *Página de inicio - Cámara Nacional de la Industria Tequilera*. Obtenido de Cámara Nacional de la Industria Tequilera: <https://www.cnit.org.mx/>

De o Santos Júnior, D. S., De Mattos Neto, P. S., De Oliveira, J. F., & Cavalcanti, G. D. (2023). A hybrid system based on ensemble learning to model residuals for time series forecasting. *Information Sciences*, 649, 119614. <https://doi.org/10.1016/j.ins.2023.119614>

Google Cloud. (2023). Vertex AI Pricing. <https://cloud.google.com/vertex-ai/pricing>

Gómez, A. C., Bejarano, L. A., & Espitia, H. E. (2024). Artificial Neural Network Model to Predict the Exportation of Traditional Products of Colombia. *Computation*, 12(11), 221. <https://doi.org/10.3390/computation12110221>

Introducción a la memoria a corto-largo plazo (LSTM). (s. f.). MATLAB & Simulink. <https://la.mathworks.com/discovery/lstm.html>

What Is an ARIMAX Model?. (21 de April de 2023). Obtenido de 365datascience: <https://365datascience.com/tutorials/python-tutorials/arimax/>

Agradecimientos

Agradecemos profundamente a nuestras familias, parejas y amigos por su incondicional apoyo, paciencia y comprensión a lo largo de esta etapa. Su presencia, ánimo y confianza fueron fundamentales para mantenernos firmes durante los momentos de mayor esfuerzo.

Expresamos nuestro sincero agradecimiento a nuestra asesora, la Dra. Grettel, por el tiempo dedicado a orientarnos, así como por sus valiosos consejos, palabras de aliento y constante apoyo a lo largo de este proceso.

Asimismo, agradecemos al Lic. Felipe Villalobos Serrano por habernos brindado la oportunidad de desarrollar este proyecto, así como por la confianza y libertad que nos otorgó desde el inicio.

¡GRACIAS POR SU ATENCIÓN!