



Tecnológico de Monterrey

Instituto Tecnológico y de Estudios Superiores de Monterrey

Escuela de Ingeniería y Ciencias

Maestría en Inteligencia Artificial Aplicada

Dra. Grettel Barceló Alonso

Dr. Luis Eduardo Falcón Morales

Materia Proyecto integrador

Avance 7. Resumen ejecutivo

Equipo 11

José Gilberto Amaro Aceves - A01794815

Francisco Antonio Enríquez Cabrera - A01795006

Carlos Eduardo García García - A01795206

15-06-2025

Índice

Síntesis del problema.....	3
Hallazgos más importantes del análisis exploratorio de datos.....	4
Hallazgos posteriores al análisis exploratorio	4
Modelos generados y razones de la elección del modelo final	8
Walk forward validation	10
Solución final	12
Métricas de desempeño	18
Recomendaciones clave para implementar la solución	20
Análisis costo – beneficio	28
Recomendación	32
Beneficios Potenciales del Proyecto	32
Riesgos y desafíos de la solución	33
Bibliografía	36

Síntesis del problema

El proyecto es realizado para la Cámara Nacional de la Industria Tequilera quien es una institución que ofrece acciones y servicios para fortalecer la cadena productiva, al igual que oportunidades de negocio para mejorar la competitividad de sus miembros.

La cámara ofrece a las empresas la libertad de poder unirse de manera voluntaria en cualquier momento para trabajar por el beneficio del tequila, esto mediante acuerdos y condiciones que permiten la competitividad a nivel nacional e internacional (CNIT, s.f.)

Esta cámara tiene como objetivo “representar, promover y defender los intereses comunes de sus asociados, proponiendo y llevando a cabo las acciones que satisfagan sus necesidades y expectativas para fortalecer el prestigio e imagen de la Industria Tequilera en general y del Tequila en particular” (CNIT, s.f.).

¿Cuál es el problema?

La cámara busca atender la necesidad que enfrentan las tequileras para estimar con precisión cuánto producto debe producir mensualmente y planear con anticipación el cultivo de agave azul necesario para su elaboración.

El principal objetivo es pronosticar las exportaciones totales por tipo de tequila y más específico, pronosticar la exportación de tequila a Estados Unidos, siendo este país el cliente con mayor cantidad de exportaciones de tequila con un estimado de 87% del mercado según los datos obtenidos del CNIT.

¿Por qué es importante resolver este problema?

Permitirá optimizar, balancear la cantidad de agave necesario respecto a la demanda y consumo para la producción del tequila, minimizando mermas y optimizando las ganancias de las tequileras.

¿Cuál es la meta prevista?

La meta prevista es desarrollar tres modelos de ML que realicen tres escenarios posibles sobre la proyección de exportaciones y un cuarto modelo para la proyección del consumo de agave; la integración de la data implica la implementación de una API para lograr una automatización de la ejecución de los modelos.

Hallazgos más importantes del análisis exploratorio de datos

Durante la fase del análisis exploratorio de datos encontramos se realizaron varias actividades, entre ellas fueron la obtención de datos, preprocesamiento y descubrimientos.

Consideramos que los siguientes hallazgos fueron los más importantes:

1. Los datos se encuentran alojados en línea y se encuentran disponibles al público general, este se actualiza una vez al mes, los días 8 de cada mes.
2. Dentro de estos distintos reportes tenemos en la mayoría la recurrencia de las mismas características y misma estructura, siendo 3 registros por año, uno por el valor de la subcategoría “Tequila”, otro por el valor de la subcategoría “Tequila 100%” y un último registro del valor total de ese año.
3. No se encontraron valores nulos en ninguna instancia.
4. No hay una correlación fuerte entre ninguna de las características originales.

Hallazgos posteriores al análisis exploratorio

Uno de los hallazgos de información posterior a la etapa de análisis exploratorio fue la realización de la descomposición de los datos temporales lo cual se encontró que en el caso de los datos la división del tradicional 80% de muestra para entrenamiento y 20% de pruebas no funcionaba para estos escenarios.

Analizando las gráficas (gráficas 1 y 2), se puede llegar a formular el siguiente problema: si hacemos una segmentación 80-20 (por ciento) de los datos, siendo el 80% para los datos de entrenamiento y el 20% para la prueba y validación, y dada la naturaleza de la serie, los cambios súbitos en la aceleración o desaceleración de la tendencia no logran ser captados con el primer segmento; los datos de entrenamiento y validación se alejarán drásticamente de los puntos predichos.


Se llegó a la hipótesis de que este cambio drástico de comportamiento fue consecuencia de la pandemia del COVID-19, por lo cual se agregó un marcador a esta gráfica para ofrecer un punto de comparativa.

Cabe destacar que el primer cambio abrupto en los datos se observó en diciembre de 2019, coincidiendo con la aparición global del COVID-19, aunque la pandemia fue reconocida oficialmente en México hasta finales de febrero de 2020.

El método que se utiliza para hacer la descomposición es `seasonal_decompose` de la paquetería `statsmodels`. La técnica consiste en descomponer los valores observados (serie original) en tres componentes: tendencia, estacionalidad y el residuo o ruido.


La estimación de la tendencia es a través de un suavizado con el uso de ventanas móviles, promediando 12 meses (6 meses anteriores y 6 meses posteriores al mes de la serie). La estacionalidad se calcula en dos etapas: en la primera, se obtiene la diferencia entre el punto original de la serie menos el valor de la tendencia calculada por las ventanas móviles; para la segunda etapa, se hace una agrupación de los valores obtenidos (en la etapa 1) por las estaciones elegidas (en este caso 12) y se calcula el promedio de los años acumulados según el periodo observado. Finalmente, se puede hacer una normalización de los valores estacionales: restando a los valores estacionales el promedio de ellos para cada ventana. Los valores de los residuos son la resta del valor original menos la componente de estacionalidad.

En las gráficas 1 y 2, se muestran las descomposiciones para las series por tipo de tequila. Para el tipo TEQUILA, la tendencia es creciente por etapas, la primera etapa comprende desde el año 1995 hasta poco después del 2000, seguido de una etapa estacionaria (desde 2006 hasta el año 2020), posteriormente hay nuevamente un crecimiento mucho más acelerado que en los primeros años. La estacionalidad es periódica; sin embargo, existe mayor fluctuación en los residuos, en donde a partir del año 2019 la amplitud de los residuos supera la vecindad de ± 2 unidades.



Gráfica 1. Descomposición de la tendencia por Categoría para el tipo *Tequila*: Serie original (superior), gráfica de la tendencia (medio superior), gráfica de la estacionalidad (medio inferior) y gráfica de los residuos (inferior).

La tendencia para el tipo TEQUILA 100% es creciente de forma global, presentando su mayor aceleración de crecimiento a partir del año 2020. La estacionalidad también es periódica, aunque el hallazgo de mayor relevancia está en la gráfica de los residuos (gráfica 2, parte inferior), el ruido detectado supera la vecindad de ± 4 unidades después del año 2020, teniendo en el periodo anterior valores promedio de 1.5 unidades. Este evento es fundamental para entender los resultados obtenidos.




Gráfica 2. Descomposición de la tendencia por Categoría para el tipo *Tequila 100%*: Serie original (superior), gráfica de la tendencia (medio superior), gráfica de la estacionalidad (medio inferior) y gráfica de los residuos (inferior).

En las gráficas 3 y 4, se muestran las descomposiciones de las exportaciones para el país Estados Unidos de América por tipo de tequila. Para el tipo TEQUILA (gráfica 3), la tendencia está descrita por etapas, en donde se muestran crestas y valles globales, el crecimiento más acelera se encuentra en el año 2020 pero con un descenso en el año 2023. La estacionalidad es periódica. Los residuos se encuentran dentro de la banda $\pm$


2 unidades para la mayoría de los puntos antes del año 2020, sin embargo, a partir de esa fecha, hay una mayor fluctuación.

La tendencia para el TEQUILA 100%, es creciente de manera global (gráfica 4, superior), el crecimiento más acelerado es a partir del año 2020, tiene una estacionalidad periódica, y la mayor fluctuación del ruido está en el mismo año que aceleró su crecimiento (gráfica 4, inferior).

Las observaciones realizadas para la serie del país de Estados Unidos de América, son consistentes con las observaciones para la serie global, esto debido a que la participación de este país está es aproximadamente el 87% del total de exportaciones.



Gráfica 3. Descomposición de la tendencia para el país Estados Unidos de América para el tipo *Tequila*: Serie original (superior), gráfica de la tendencia (medio superior), gráfica de la estacionalidad (medio inferior) y gráfica de los residuos (inferior).



Gráfica 4. Descomposición de la tendencia del país Estados Unidos de América para el tipo *Tequila 100%*: Serie original (superior), gráfica de la tendencia (medio superior), gráfica de la estacionalidad (medio inferior, gráfica de los residuos (inferior).

Modelos generados y razones de la elección del modelo final

En esta sección hablaremos sobre los modelos generados durante el desarrollo del proyecto en orden cronológico.


Para establecer una línea base, se construyó un estimador con **RandomForest**. Aunque no es un modelo especializado en series de tiempo, permitió establecer un punto de comparación inicial para los modelos posteriores.

En las primeras etapas del proyecto se exploraron modelos de aprendizaje automático que no incorporan explícitamente la secuencia temporal. Sin embargo, al integrar variables derivadas de la fecha (como mes o trimestre) y transformaciones cíclicas, fue posible capturar parte de la dinámica temporal.


Sin embargo, fue hasta que se empezó a refinar más el preprocesamiento de datos e ingeniería de características, al igual que la implementación de modelos especializados a series de tiempo, como lo es **ARIMAX** y **LSTM** que fue cuando nuestras predicciones empezaron a mejorar significativamente.

ARIMAX fue el primer modelo con el cual se empezó a experimentar, debido a que su implementación es relativamente sencilla, requiriendo que los datos tengan un índice de fecha y estos cuenten con una frecuencia establecida, además de que permite la integración de valores exógenos en el modelo para ayudar a mejorar las predicciones, aunque en nuestro caso, estos valores fueron metadatos extraídos de la fecha en la ingeniería de características (What Is an ARIMAX Model? , 2023).

LSTM (Long short-term memory), por otro lado, es una red neuronal con una arquitectura diferente a la convencional que se enfoca en capturar dependencias largas y cortas en datos secuenciales, lo cual es ideal para problemas de predicciones en series de tiempo.



Gráfica 5. Primeros resultados de implementación de un LSTM para la serie exportaciones de la categoría TEQUILA.



Gráfica 6. Primeros resultados de LSTM para la serie exportaciones para la categoría TEQUILA 100%.

Después de generar pruebas con estos modelos, logramos mejorar significativamente las predicciones a comparación de otros métodos, sin embargo, estos resultados no fueron tan consistentes como deseamos por qué nuevamente recaímos en que los datos de entrenamiento no describían los valores de pruebas por lo cual se decidió adoptar una estrategia distinta usando **“Walk forward validation”**.

Walk forward validation

Walk forward validation, en este tipo de validación podemos evaluar el desempeño de nuestro modelo en un escenario más realista tal como si fuera producción (Ahmed Fahad, 2024).

En este tipo de validación se dividen los datos en ventanas de tiempo consecutivas, estas ventanas siendo una ventana de entrenamiento y otra de pruebas.

El objetivo es con este subconjunto de datos de entrenamiento de tamaño N procesar, entrenar y predecir M cantidad de datos, siendo el largo de esta ventana de pruebas la que indica el paso con el que se mueven las predicciones.





Figura 1. Explicación visual de Walk-forward validation: cada fila (fold) representa un segmento de validación secuencial. Las secciones azules corresponden al conjunto de entrenamiento, las rojas al conjunto de validación, las grises a los datos por observar y las blancas a los periodos excluidos; basado en (Börjesson & Singull, 2020)

Con esta nueva implementación adaptamos la solución para poder aprovechar “Walk-forward validation”, entre las cosas que se hicieron fue el determinar el tamaño de la ventana de entrenamiento y de pruebas, en este caso es importante poder incluir un tamaño suficiente para que el modelo usado pueda aprovechar los valores de entrenamiento y poder observar patrones significativos.

En nuestro caso, decidimos optar por ventanas de 36 meses donde después implementamos una ventana corrediza de 24 meses para el entrenamiento del LSTM el cual al final solo tiene como objetivo retornar una sola predicción.

La decisión de que la ventana de predicción fuera de un solo paso fue realizada para brindar un mejor desempeño en los escenarios explicados anteriormente donde al final del historial de valores hay un aumento de ruido significativo, esto a costo de un mayor costo computacional.



Gráfica 7. Experimento de usar un modelo LSTM con “Walk-forward validation” para la serie exportaciones, categoría TEQUILA 100%.


Cabe destacar que como menciona Ahmed Fahad, esta validación tiene tanto ventajas como desventajas, siendo la ventaja mas significativa para el problema el capturar patrones evolutivos dentro de los datos, y como mayor desventaja tenemos el alto costo computacional que implica iterar constantemente todos los pasos para conseguir un modelo entrenado.

Solución final


Por último, se combinaron dos estrategias durante el desarrollo del proyecto: por un lado, el uso del algoritmo de “Walk-forward”; por otro, la ejecución de dos modelos, uno para la suma de la estacionalidad con la tendencia y otro, para los residuos (ruido), generando con la suma de ambas predicciones, el valor deseado a predecir.

A continuación, mostraremos todas las predicciones obtenidas haciendo uso de este nuevo acercamiento.


Validaciones de la nueva implementación usando Walk-forward:




Grafica 8. Walk-Forward validation de la producción total de tequila: pronóstico +1 mes de horizonte.




Grafica 9. Walk-Forward validation de la producción total de tequila 100%: pronóstico +1 mes de horizonte.




Grafica 10. Walk-Forward validation de la exportación total de tequila 100%: pronóstico +1 mes de horizonte.




Grafica 11. Walk-Forward validation de la exportación total de tequila 100%: pronóstico más 1 mes de horizonte




Grafica 12. Walk-Forward validation de la exportación total de Estados Unidos, tequila 100%: pronóstico +1 mes de horizonte.



Grafica 13. Walk-Forward validation de la producción total de Estados Unidos, tequila 100%:..




Grafica 14. Walk-Forward validation de la producción total de tequila 100%.




Grafica 15. Walk-Forward validation de la producción total de tequila 100%.

Transformada de Fourier



Gráfica 16. Transformada de Fourier sobre predicciones de exportación de tequila 100% a estados unidos.



Gráfica 17. Zoom a la transformada de Fourier sobre predicciones de exportación de tequila 100% a estados unidos.

La importancia del uso de la Transformada Rápida de Fourier sobre la serie predicha bajo nuestro modelo es que permite comparar las frecuencias dominantes actuales con las salidas del modelo LSTM. Con estas gráficas podemos decir con confianza que el

modelo fue capaz de aprender el comportamiento de los valores sobre el tiempo debido a que las dos líneas se están sobreponiendo una sobre la otra mostrando que el comportamiento predicho es casi igual al de los valores originales.


Métricas de desempeño

El modelo Híbrido LSTM+Walk Forward, no fue el único algoritmo probado. En la **tabla X**, se enlistan los modelos enfocados en Machine Learning con los que experimentamos. Se usaron modelos basados en árboles de Decisión (ExtraTrees, GredientBosting), Modelos lineales y de Vecinos Cercanos (RiDge, Linear Regression, KVeninos); finalmente una red neuronal recurrente (RNN).

Tipo / Enfoque	Modelo	MAE	RMSE	R²
Red Neuronal Recurrente + Decomposición Estacional	LSTM A+B (Walk-Forward)	0.85	1.45	0.96
Ensamble de Árboles (Bagging)	ExtraTrees	1.77	2.41	-0.41
Ensamble de Árboles (Boosting)	GradientBoosting	1.86	2.51	-0.50
Ensamble de Árboles (Boosting)	HistGradientBoosting	1.92	2.59	-0.52
Árbol de Decisión	DecisionTree	2.11	2.82	-0.74
Vecinos Cercanos (Geométrico)	KNeighbors	2.25	2.75	-0.20
Regresión Lineal (L1)	Lasso	2.38	2.89	-0.65
Máquina de Soporte Vectorial	SVR	2.60	3.33	-0.68
Regresión Lineal (L2)	Ridge	3.51	4.14	-4.08
Regresión Lineal	LinearRegression	3.52	4.15	-4.10
Modelo Base (Media/Constante)	Dummy	3.54	4.07	-1.79

Tabla 1. Modelos y métricas de desempeño implementados durante el desarrollo del proyecto: Las métricas mostradas, corresponden al entrenamiento de las exportaciones totales. MAE: promedio de las diferencias absolutas entre los valores predichos y los

valores reales. RMAE: raíz cuadrada del promedio del cuadrado de la diferencia entre los valores reales y predichos. R^2 coeficiente de determinación.



Gráfica 18. Valores de las métricas de desempeño usadas como evaluadores. Error Absoluto Medio (MAE) (columna verde): Indica cuánto se equivoca el modelo. Raíz del Error Cuadrático Medio (RMSE (columna amarilla): penaliza los errores grandes, sensible a outliers. Coeficiente de Determinación (línea roja): un valor cercano a 1 tiene una significancia o gran poder de explicación del modelo.

Para las métricas de MAE y RMSE, el valor guía es cero, mientras que, para el coeficiente de determinación, el horizonte es el valor 1. Con base en estas tres métricas, concluimos que el modelo con mejor desempeño es el híbrido: LSTM +Walk Forward, con valores de . MAE 0.85 (millones de litros), RMSE: 1.45 (millones de litros) y R^2 : 0.96.

Recomendaciones clave para implementar la solución

El código ha sido estructurado mediante tres partes principales:

- Un webscrapper para conseguir los datos de la página de los informes del CNIT.
- Una implementación de un DVC pipeline para la preparación y preprocesamiento de los datos.
- Modelado de inteligencia artificial.

Para la implementación de esta solución recomendamos mantener actualizados los datos mediante el uso del Webscrapping una vez al mes ya que esta es la frecuencia con la que estos datos son actualizados en el sitio oficial.

Una vez obtenidos los datos actualizados, correr el pipeline de DVC para obtener los conjuntos de datos divididos ya en sus distintos subconjuntos al igual que la separación del conjunto de entrenamiento y pruebas.

Por último, ejecutar el entrenamiento del modelo con los nuevos datos para poder tener siempre el mejor modelo disponible y evitar el “data drift”.




Figura 2. Diagrama de la estructura general del código.

El código funciona mediante un DVC pipeline que está estructurado en distintos archivos, estos siendo:

- Pasos/Scripts
- Configuraciones

- Parámetros

Para DVC, existen dos archivos importantes que es el de configuración del pipeline y otro el de parámetros.

El de configuración indica que comando de consola va a usar para ejecutar los códigos, que dependencias tienen estos pasos del pipeline y que parámetros son los que tiene que observar para cambios al igual que las salidas de estos pasos.

Por otro lado, se maneja un segundo archivo yaml para los parámetros que se usan, DVC junto a las configuraciones de dependencias y parámetros maneja un control de versiones interno el cual permite diferenciar cuando uno de estos cambia y si un paso requiere este valor y nota un cambio fuerza a que este paso se vuelva a ejecutar. Este archivo de parámetros simplemente es una manera en la cual se listan los parámetros y que nosotros podemos modificar en cualquier momento y desarrollar experimentos con ellos.

```

stages:
  prepare:
    cmd: python pipeline/prepare.py
    deps:
      - data/consolidado_consumodeagavetotal.csv
      - data/consolidado_exportaciones_pais.csv
      - data/consolidado_exportacionestotalcategoria.csv
      - data/consolidado_exportacionestotalforma.csv
      - data/consolidado_producciontotaltequila.csv
    params:
      - prepare.seed
      - prepare.train_split
      - prepare.files
    outs:
      - data/pipeline/prepared
  preprocessing:
    cmd: python pipeline/preprocess.py data/pipeline/prepared data/pipeline/preprocessed
    deps:
      - data/pipeline/prepared
    params:
      - preprocess.target
      - preprocess.low_var
      - preprocess.high_corr
      - preprocess.seed
      - preprocess.files
  train_and_predict:
    cmd: python pipeline/train_and_predict.py data/pipeline/prepared data/pipeline/train_and_predict
    deps:
      - data/pipeline/prepared
    params:
      - wf_train_and_predict.walking_forward.window_size
      - wf_train_and_predict.walking_forward.predict_window
      - wf_train_and_predict.months_to_predict
      - wf_train_and_predict.low_var
      - wf_train_and_predict.high_corr
      - wf_train_and_predict.export_graphs
      - wf_train_and_predict.files

```

Figura 3. Estructura del archivo dvc.yaml

```

version_label: "0.1"
preprocessing:
  CONTINENTE_MAP:
    "ESTADOS UNIDOS DE AMERICA": "America"
    "CANADA": "America"
    "BRASIL": "America"
    "ALEMANIA": "Europa"
    "FRANCIA": "Europa"
    "REINO UNIDO": "Europa"
    "ESPAÑA": "Europa"
    "CHINA": "Asia"
    "JAPON": "Asia"
  LOW_VAR_THRESHOLD: 0.01
  HIGH_CORR_THRESHOLD: 0.95
prepare:
  train_split: 0.80
  seed: 42
  files:
    - path: "consolidado_exportaciones_pais.csv"
      subcategoria_col: "Categoria"
    - path: "consolidado_exportacionestotalcategoria.csv"
      subcategoria_col: "SubCategoria"
    - path: "consolidado_consumodeagavetotal.csv"
      subcategoria_col: "SubCategoria"
    - path: "consolidado_producciontotaltequila.csv"
      subcategoria_col: "SubCategoria"
preprocess:
  target: "Valor"
  low_var: 0.01
  high_corr: 0.95
  seed: 42
  files:
    - file_name: "exportaciones_pais"
      subcategoria_col: "Categoria"
    - file_name: "exportacionestotalcategoria"
      subcategoria_col: "SubCategoria"
    - file_name: "consumodeagavetotal"
      subcategoria_col: "SubCategoria"
    - file_name: "producciontotaltequila"
      subcategoria_col: "SubCategoria"
wf_train_and_predict:
  walking_forward:
    window_size: 36
    predict_window: 1
  months_to_predict: 84
  low_var: 0.01
  high_corr: 0.95
  export_graphs: true
  files:
    - "exportaciones_pais"
    - "exportacionestotalcategoria"
    - "consumodeagavetotal"
    - "producciontotaltequila"
mlflow:
  run_name: "Run for {model}"
  experiment_name: "TequilaExportaciones"
  tracking_uri: "http://127.0.0.1:5000"

```

Figura 4. Archivo de parámetros YAML (params.yaml)

Después de estas configuraciones tenemos lo que son los pasos que se encuentran dentro de las configuraciones de dvc.yaml.




Figura 5. Estructura de archivos del pipeline.

Tal como se muestra en la figura 5, la estructura es bastante sencilla y podemos tratarla como sea necesario, en este caso se dividieron en los pasos necesarios para llegar a la conclusión del modelo.

El archivo de “prepare.py” se enfoca meramente en la división de los datos crudos, se eliminan las filas con los totales, se separan en distintos datasets las subcategorías para obtener datasets con un solo registro por mes, logrando una consistencia “temporal” en los datos, al igual que hacer la división de los datos en distintos archivos, tanto como uno de pruebas, otro de entrenamiento y al final uno completo, esto nos brinda una mayor libertad a la hora de querer manejar estos datos.

Por otro lado, el archivo de “preprocess.py” es donde realizamos todo el preprocesamiento de los datos de una manera organizada, en este separamos las funciones para ser reusadas de ser necesario al importarlas en otro archivo y en este archivo directamente trabajamos con los archivos generados en “prepare.py”.

Al final tenemos el archivo de “train_and_predict.py” que es el archivo principal para nuestro proyecto, donde hacemos la predicción de los valores, en este caso asignamos la dependencia con la salida de “prepare.py” ya que no manejamos el tradicional Split de entrenamiento-pruebas tal como se explicó con anterioridad.

Sin embargo, esto no implica que el archivo de “preprocess.py” no sea importante ya que de este mismo archivo importamos la función de feature_engineering que nos ayuda a hacer el preprocesamiento de nuestras ventanas de entrenamiento y pruebas y con este podemos trabajar en distintas maneras bajo el mismo código y sin necesidad de estar manejando múltiples libretas, solo archivos con propósitos bien definidos en el desarrollo del modelo.

Por último, contamos con lo que son las salidas de estos archivos, que son manejados de la misma manera en la cual fueron realizados los pasos, en subcarpetas bajo el mismo nombre del paso para una mayor claridad y consistencia.




Figura 6. Estructura de archivos de salida del pipeline de DVC.


Para la ejecución del pipeline, solo debemos tener las librerías necesarias instaladas en nuestro entorno y hacer uso del comando:

dvc repro


O en caso de ser necesario, podemos forzar una ejecución total de los pasos usando el comando:

dvc repro -f


Una vez ejecutado el pipeline podemos observar nuestros resultados de dos formas, a través de gráficas y a través de un archivo CSV con los valores predichos tal como se muestra en las siguientes graficas.




Gráfica 19. Proyección de las exportaciones de tequila por país (Estados Unidos) para los siguientes 7 años.



Gráfica 20. Proyección de las exportaciones de tequila 100% de agave por país (Estados Unidos) para los siguientes 7 años.



Gráfica 21. Proyección de las exportaciones de tequila por categoría para los siguientes 7 años.



Gráfica 22. Proyección de las exportaciones totales de tequila 100% de agave para los siguientes 7 años.

Una vez explicado esto, el código fue estructurado de una manera con la cual solo se tienen que listar el resto de los archivos no trabajados para también implementar predicciones para los mismos, al igual que otros países y, aunque con un poco más de trabajo requerido, se pueden adaptar lo suficiente para aumentar la granularidad de estas divisiones dentro de las clases de tequila dentro del archivo de exportaciones de tequila por país.

Como una nota importante, por la naturaleza del modelo de LSTM (Long Short Term Memory), el modelo es propenso a memorizar hasta cierto punto los comportamientos del ruido e irlos replicando tal como se muestra en la gráfica sobre las exportaciones de tequila 100% a estados unidos, donde vemos una caída significativa en la cantidad de exportaciones, sin embargo, nosotros sabemos que esta caída se debe a la situación geopolítica con los aranceles impuestos y la inteligencia artificial desconoce que esta situación es fuera de lo normal y no debería de ser considerada para la predicción.

Análisis costo – beneficio

En la siguiente sección se enumeran todos los costos incurridos (relacionados con la adquisición de datos, el uso de servidores, servicios en la nube, y cualquier hardware o software específico necesario) divididos por fase de la metodología CRISP-ML para dos plataformas recomendadas Google Cloud Platform (GCP) y Amazon Web Services (AWS).

Así mismo se identifican los costos esperados para la operación y mantenimiento del modelo.

En la tabla 1, se presenta una estimación de costos por etapa de la metodología CRISP-ML, bajo el escenario de implementación bajo la plataforma GCP con dos modelos de servicios PaaS (Plataforma como servicio) y SaaS (Software como servicio). Las diferencias principales es el alcance de los modelos sobre la gestión de los recursos.

Etapas CRISP-ML	SaaS (Vertex AI) Gestionado	PaaS (GCP) Autogestionado	Referencia
1. Entendimiento del negocio y de la data.	Suscripción a herramientas como Looker, BigQuery Notebook gestionado: ~ \$0.10/h	Compute Engine n1-standard: ~\$0.15/h + Cloud Storage ~\$0.026/GB por mes.	https://cloud.google.com/vertex-ai/pricing

2. Adquisición y Entendimiento de la data.	BigQuery UI: \$5/TB procesado + \$0.02/GB por mes almacenamiento	Dataflow: \$0.056/vCPU·h + \$0.0035/GB·h RAM + \$0.011/GB shuffle	https://cloud.google.com/bigquery/pricing
3. Preprocesamiento de la data.	Incluido en plataformas como Vertex AI Pipelines, BigQuery ML.	Scripts ETL en Dataflow o Cloud Functions. Costo de instancias + procesamiento	https://cloud.google.com/dataflow/pricing
4. Modelado	AutoML con GPU (Tesla T4): ~\$0.35/h + VM ~\$0.38/h	Instancias con GPU configuradas manualmente. Misma tarifa por hardware	https://cloud.google.com/vertex-ai/pricing#training_pricing
5. Evaluación del Modelo	SHAP/LIME integrados en Vertex AI. Costo incluido	Ejecución en instancias n1-standard (~\$0.10–0.15/h) + librerías open source	https://cloud.google.com/vertex-ai/docs/explainable-ai/overview
6. Deployment	Vertex AI endpoint: ~\$0.10/h por nodo + autoscaling incluido	Cloud Run / GKE: ~\$0.10–0.15/h por instancia + tráfico adicional	https://cloud.google.com/vertex-ai/pricing#prediction_pricing
7. Monitoreo y Mantenimiento	Incluido: logging, drift detection, auditoría automática	Stack propio (MLFlow, Prometheus). Logging ~\$0.02/GB por mes + horas hombre	https://cloud.google.com/logging/pricing

Tabla 2. Ejemplo de uso: Comparativa de costos en la plataforma GCP usando los modelos SaaS (Software as a Service) y PasS (Platform as a Service). Los valores están expresados en dólares estadounidenses (USD) y están sujetos a cambios según el tipo de instancia, región y volumen de procesamiento.

En la tabla 2, se ejemplifican los desgloses del costo estimado de las posibles componentes a implementar bajo la metodología CRISP-ML.

Componente	SaaS (Vertex AI)	PaaS (GCP autogestionado)	Referencia
Notebook /EDA	100 horas x \$0.10 = \$10	100 h x \$0.15 = \$15	Vertex AI Workbench: n1-standard-4 ≈ \$0.10/h https://cloud.google.com/vertex-ai/pricing
Bigquery + Storage	2 TiB de consulta = \$10 500 GB de almacenamiento activo = \$10	2 TiB de consulta = \$10 500 GB de almacenamiento activo = \$10	BigQuery Query: \$5/TiB consultado; Storage: \$0.02/GB·mes https://cloud.google.com/bigquery/pricing
ELT (Dataflow)	Incluido (en SaaS no se factura separado)	100 h x 2 vCPU = 200 vCPU·h x \$0.056 = \$11.2	https://cloud.google.com/dataflow/pricing
Modelado con GPU	10 h x (\$0.35 + \$0.38) = \$7.3	10 h x (\$0.35 + \$0.38) = \$7.3	GPU Tesla T4 + n1-standard-4 VM https://cloud.google.com/vertex-ai/pricing#training_pricing
Inferencia	100 h x \$0.10 = \$10	100 h x \$0.15 = \$15	Vertex AI endpoint vs. Cloud Run / GKE
Monitoreo y logging		~50 GB logs x \$0.02 = \$1	Operations suite logging https://cloud.google.com/logging/pricing
Total Estimado	≈ \$37/mes (USD)	≈ \$49/mes (USD)	

Tabla 3. Desglose del cálculo estimado de costos mensuales usando los servicios SaaS y PaaS, bajo la metodología CRISP-ML. Los valores están expresados en dólares estadounidenses (USD) y corresponden a un escenario de uso moderado. Las tarifas fueron obtenidas de fuentes oficiales de Google Cloud Platform. Para una estimación precisa y actualizada, se recomienda utilizar el GCP Pricing Calculator.

Otra plataforma en la nube adecuada para la ejecución del proyecto es Amazon Web Services (AWS), en la tabla 3, se muestran

Etapa CRISP-ML	AWS (SageMaker / Gestionado)	Referencia
1. Entendimiento del negocio y de la data.	SageMaker Studio Notebooks (~\$0.05/h, ml.t3.medium)	https://aws.amazon.com/es/sagemaker-ai/studio/
2. Adquisición y Entendimiento de la data.	Data Wrangler + Glue Data Catalog (incluido en Studio)	https://docs.aws.amazon.com/sagemaker/latest/dg/data-wrangler.html
3. Preprocesamiento de la data.	SageMaker Pipelines + EMR (según uso, ~\$0.11/vCPU ·h)	https://aws.amazon.com/es/sagemaker-ai/pipelines/
4. Modelado	AutoPilot, GPU/Trainium (25–37% menos que GCP)	https://cloudexpat.substack.com/p/cloudexpat-benchmarking-2023

5. Evaluación del Modelo	AutoPilot explainers (SHAP), ML Lineage (sin cargo extra)	https://docs.aws.amazon.com/sagemaker/latest/dg/whatis.html
6. Deployment	Endpoints serverless (~\$0.0005 por invocación)	
7. Monitoreo y Mantenimiento	Model Monitor + CloudWatch (~\$0.03/GB logs)	https://docs.aws.amazon.com/sagemaker/latest/dg/model-monitor.html

Tabla 4. Estimación de las capacidades y costos de AWS SageMaker, basados en la metodología CRISP-ML. Los enlaces proporcionan acceso a documentación oficial y estudios comparativos de costos en dólares americanos.

Recomendación

Ponderando facilidad de adopción, catálogo de servicios avanzados, escala global con región local y coste total de propiedad (incluyendo la prueba comparativa de costos de entrenamiento) AWS se mantiene como la opción óptima. SageMaker unifica todo el ciclo de vida de ML, su región mexicana minimiza latencia y residencia de datos, y su estructura de precios flexible (spot, savings plans) permite entrenar el modelo walkingforward de una hora con ahorro respecto a GCP (CloudExpat, 2023). Para cargas analíticas masivas o IA generativa específica, GCP podría superar en ciertos subescenarios.

Beneficios Potenciales del Proyecto

A continuación, enunciamos algunos de los beneficios potenciales que destacamos del proyecto desde la perspectiva operativa, optimización de recursos y toma de decisiones.

1. **Perspectiva Operativa:** permite establecer una correlación analítica entre la producción y exportación con la demanda estimada a nivel país y categoría, reduciendo sobrecostos por inventario o capacidad de acuerdo con la estacionalidad.
2. **Perspectiva de Optimización de recursos:** es posible anticipar los volúmenes para ciertos periodos identificados en donde las variables exógenas entren poco en juego. Las desviaciones respecto a la estacionalidad esperado también es una métrica para detectar eventos de tipo exógeno por ejemplo aquellos cambios disruptivos en el comportamiento de los clientes y de cambios en políticas comerciales.
3. **Perspectiva en la toma de decisiones:** El proyecto provee un marco de análisis predictivo estableciendo métricas analíticas de confiabilidad sustentadas en la información que puede inferir desde la data. La trazabilidad de los datos y el monitoreo de las tendencias del modelo con nuevos datos permite anticipar incumplimientos e identifican nuevas oportunidades a nivel país con crecimiento sostenido.

Riesgos y desafíos de la solución

¿Cuáles son los riesgos o desafíos potenciales de la solución propuesta?

El proyecto enfrenta cuatro frentes de riesgo estrechamente relacionados. Primero, la calidad y vigencia de los datos: después de la pandemia la serie cambió de forma abrupta y, si vuelve a hacerlo, el modelo exigirá re-entrenamientos más frecuentes; además, basta que el CNIT retrase la publicación o altere el formato de su portal para que el “scraper” deje huecos y las predicciones se degraden. Segundo, la seguridad del flujo de información: un atacante podría insertar valores falsos en la fuente o enviar consultas maliciosas al endpoint para forzar salidas absurdas o incluso reconstruir el LSTM, erosionando la ventaja competitiva. Tercero, la confianza en los resultados: los picos del componente residual siguen siendo difíciles de anticipar, lo que puede inducir sobre- o sub-producción de agave, y la arquitectura híbrida —percibida como “caja negra”— privilegia el mercado estadounidense, lo que genera dudas internas sobre sesgo y explicabilidad. Por último, el cumplimiento normativo: la automatización y redistribución de datos públicos puede requerir acuerdos explícitos con el CNIT; procesar la información fuera de México o sin trazabilidad completa pondría al proyecto en conflicto con futuras exigencias de soberanía de datos y regulaciones de IA confiable.

Clasificación de los riesgos identificados en las categorías de riesgos asociados a datos, ataques AI/ML, prueba y confianza y cumplimiento

Categoría AIRS	Riesgo / desafío	Descripción concreta	Efecto en costos y beneficios
1. Datos – limitaciones de aprendizaje	Deriva de datos (data drift)	Cambios estructurales en la demanda tras eventos disruptivos (p. ej. fin de pandemia, variaciones arancelarias).	Re-entrenamientos más frecuentes → ↑ horas-GPU, ↑ horas de ingeniería.
	Variables exógenas limitadas	El modelo se apoya casi sólo en información temporal; no integra precio del agave, tipo de cambio o campañas de marketing.	Mayor error de pronóstico en escenarios fuera de patrón → decisiones subóptimas.
1. Datos – calidad	Errores de captura / formato	El CNIT podría cambiar etiquetas, agregar columnas o alterar el layout HTML; el scraper fallaría o introduciría valores mal alineados.	Retrabajo de limpieza, paros del pipeline y posible degradación de métricas.
	Lag de actualización	El reporte oficial se publica el día 8 de cada mes; un retraso rompe la ventana “walk-forward”.	Huecos temporales → re-ejecuciones extra y posible sobre-coste de inventario.
2. Ataques AI/ML – privacidad y envenenamiento	Envenenamiento de datos	Manipulación del sitio origen (o “man-in-the-middle”) que introduce registros adulterados.	Pronósticos sesgados → sobre-/sub-producción y pérdida económica.
	Entradas adversas	Solicitudes a la API con fechas fuera de rango o volúmenes extremos para probar límites numéricos.	Caídas del servicio, inferencias absurdas, gasto de soporte.
2. Ataques AI/ML – extracción de modelos	Model-stealing	Uso intensivo del endpoint para recrear parámetros del LSTM híbrido.	Pérdida de ventaja competitiva; necesidad de rotar claves / añadir rate-limiting.

3. Pruebas y confianza – salida incorrecta	Alta varianza del componente residual	Picos ($> \pm 4$ desv. est.) no capturados por el modelo, aun tras la fase de ruido.	Sobre-/sub-estimación de existencias de agave → impacto directo en costos.
3. Pruebas y confianza – falta de transparencia	“Caja negra” del LSTM + híbrido	Complejidad del modelo dificulta explicar resultados a directivos o auditores.	Reticencia a adoptar la solución, o necesidad de invertir en herramientas de interpretabilidad.
3. Pruebas y confianza – sesgos	Enfoque en EE. UU.	Optimizar para el mercado de EE. UU. ($\approx 87\%$) puede subrepresentar otras regiones emergentes.	Pérdida de oportunidades de exportación; decisiones de marketing desbalanceadas.
4. Cumplimiento – políticas y licencias	Derechos de redistribución de datos	Aunque los informes son públicos, la automatización y republicación pueden requerir permiso escrito del CNIT.	Multas o suspensión del acceso; costos legales.
	Residencia soberana de datos	Procesamiento en nubes fuera de México podría violar lineamientos sectoriales sobre agro-industria estratégica.	Obligación de migrar infraestructura, sanciones regulatorias.
	Auditoría y trazabilidad	Si DVC o el pipeline no guardan metadatos de cada ejecución, no se puede reconstruir una predicción histórica.	No conformidad con normas ISO/FINREP; tiempo extra en análisis forense.
	Normativas emergentes de IA confiable	EU AI Act, posibles regulaciones mexicanas de IA exigirán pruebas de robustez y explicabilidad formal.	Gastos adicionales en validación, documentación y certificaciones.

Tabla 5. Riesgos AIRS identificados en el proyecto

Bibliografía

Ahmed Fahad, I. (28 de October de 2024). *Understanding Walk Forward Validation in Time Series Analysis: A Practical Guide*. Obtenido de Medium: <https://medium.com/@ahmedfahad04/understanding-walk-forward-validation-in-time-series-analysis-a-practical-guide-ea3814015abf>

Artificial Intelligence/Machine Learning Risk & Security Working Group (AIRS) (2024). Artificial Intelligence Risk & Governance. AI at Wharton. <https://ai.wharton.upenn.edu/white-paper/artificial-intelligence-risk-governance>

Börjesson, L., & Singull, M. (September de 2020). Forecasting Financial Time Series through Causal and Dilated Convolutional Neural Networks. *Entropy*. doi:10.3390/e22101094

CloudExpat. (2023, 13 diciembre). InDepth Comparison: AWS SageMaker, Azure ML, and GCP Vertex AI. CloudExpat Blog. <https://www.cloudexpat.com/blog/sagemaker-azure-ml-gcp-ai-2024/>

CNIT. (s.f.). *Cámara Tequilera*. Obtenido de Cámara Nacional de la Industria Tequilera: <https://www.cnit.org.mx/camara-tequilera/>

CNIT. (s.f.). *Página de inicio - Cámara Nacional de la Industria Tequilera*. Obtenido de Cámara Nacional de la Industria Tequilera: <https://www.cnit.org.mx/>

Google Cloud. (2023). Vertex AI Pricing. <https://cloud.google.com/vertex-ai/pricing>

What Is an ARIMAX Model? . (21 de April de 2023). Obtenido de 365datascience: <https://365datascience.com/tutorials/python-tutorials/arimax/>